

DANMARKS TEKNISKE UNIVERSITET



Prognosemodeller for vandføring fra Horsens opland

BACHELOR PROJEKT

Nicolai Garder Hansen
s224186

Nicolai Garder Hansen

26. maj 2025

Abstract

Flooding risks in Denmark are slowly increasing due to climate change and urban development, especially in regions like Horsens. Accurate and timely forecasting of water inflow is essential for proactive flood management, particularly in regulated water bodies such as Bygholm Lake. This project investigates how different time series models can be used to predict daily inflow to the lake using historical meteorological and hydrological data.

While traditional physical hydrological models are precise, they are often too complex for real-time applications. Therefore, the project explores two data-driven approaches: an autoregressive model with exogenous inputs (ARX) using Recursive Least Squares (RLS) for online learning, and a Long Short-Term Memory (LSTM) neural network designed for handling non-linear temporal dependencies. A simple persistence model serves as a baseline for performance comparison.

The evaluation shows that the LSTM model delivers the most accurate forecasts across the full dataset, outperforming the simpler models in general scenarios. However, when focusing specifically on extreme inflow events - those most relevant for flood prevention - the ARX/RLS model proves to be more stable and robust. This suggests that while neural models excel under typical conditions, simpler adaptive methods may offer critical reliability when it matters most.

Both models benefited from the inclusion of external meteorological variables. Notably, rainfall duration emerged as a key feature in both the LSTM and ARX/RLS models, underlining the importance of rain intensity in predicting inflow. Additional variables selected, such as radiation intensity, minimum temperature, and wind speed further emphasize the role of evapotranspiration in the hydrological response, as both radiation and temperature are essential for estimating potential evapotranspiration.

The results indicate that combining machine learning with meteorological and hydrological inputs can significantly improve short-term forecasting. The insights from this study can support municipal decision-makers in managing water systems more proactively and effectively, especially during high-risk periods.

Indhold

1	Introduktion	4
1.1	Motivation & formål	4
1.2	Baggrund & nuværende state-of-the-art	4
1.3	Projektoversigt	4
2	Oplande & hydrologiske funktioner	6
2.1	Evapotranspiration & nedbørsrespons	7
3	Tidsrækkeanalyse	9
3.1	Stokastiske processer	9
3.2	Tidsrækkemodeller	9
3.2.1	Autoregressive modeller	10
3.2.2	Eksogene input	10
3.3	Recursive Least Squares (RLS)	10
3.3.1	Formål & grundprincip	11
3.3.2	RLS med forgetting factor	11
3.3.3	Algoritme	11
4	Long Short-Term Memory (LSTM)	13
4.1	Recurrent Neural Network & problemet med lange sekvenser	13
4.2	Idéen bag LSTM	14
4.2.1	Forget gate	15
4.2.2	Input gate & potentiale til ny hukommelse:	15
4.2.3	Opdatering af cell state:	16
4.2.4	Output gate & ny hidden state:	16
5	Dataanalyse & eksplorativ visualisering	18
5.1	Datakvalitet	18
5.2	Overblik over datasættet & tidsserier	18
5.3	Ekstreme hændelser: Sammenhængen mellem nedbør & vandføring	21
5.4	Partial autokorrelation & lagget vandføring	23
6	Metode	24
6.1	Variabeludvælgelse & forecast-opsætning	24
6.2	Baseline: Persistensmodel	24
6.2.1	Implementering i dette Projekt	25
6.3	Model 1: ARX-model	25
6.3.1	Modelopstilling via forward selection	25
6.3.2	Implementering & online forudsigelse	26
6.4	Model 2: LSTM-model	26
6.4.1	Modelopstilling & implementering	26
6.5	Evalueringsmetrikker	28
6.5.1	Ekstreme hændelser	29
7	Resultater	30
7.1	Hele testsættet	30
7.2	Ekstreme hændelser	32

7.3	Residualanalyse	34
8	Diskussion	37
8.1	Hvilken model er bedst?	37
8.1.1	Vurdering af evalueringsmetrikker	37
8.1.2	Online vs offline forecasting	38
8.2	Eksterne variable	38
8.3	Loss-funktioner & stationaritet	39
8.4	Begrænsninger & udfordringer i modellerne	39
8.4.1	Modelkompleksitet & risiko for overfitting	39
8.4.2	Databegrænsninger	40
8.5	Perspektivering	40
8.5.1	Fremtidigt arbejde	41
9	Konklusion	42
10	Bilag	47

1 Introduktion

1.1 Motivation & formål

Klimaforandringer og øget urbanisering har sat vandressourcer under stigende pres verden over. Hyppigere ekstreme nedbørshændelser og stigende havniveau bidrager alle til øgede oversvømmelsesrisici i både by- og landområder [14]. I denne sammenhæng spiller præcise og rettidige prognoser for vandføring en afgørende rolle i forebyggende oversvømmelsesstyring.

Selvom vi i Danmark sjældent rammes af katastrofale oversvømmelser, er vi ingen undtagelse fra denne tendens. Lokale oversvømmelseshændelser er blevet mere almindelige i de seneste årtier [42], især i byområder hvor uigennemtrængelige overflader forværrer afstrømningen. Et specifikt eksempel er den voldsomme nedbør forårsaget af stormen Bodil i december 2013, som medførte betydelige oversvømmelser i Østjylland, herunder også Horsens [40]. Under sådanne hændelser kan præcise prognoser for tilløb til søer og floder muliggøre bedre beslutningstagning og mindske de samfundsmæssige og økonomiske konsekvenser af en oversvømmelse.

Dette projekt fokuserer på Bygholm Sø, en reguleret sø inden for Horsens opland. Præcise prognoser for tilløb, kan understøtte effektiv styring af sluseporte og hjælpe kommunen med at reagere proaktivt på kritiske hydrologiske forhold. Ved at udnytte historiske vejr- og hydrologiske data sammen med moderne machine-learning modeller sigter projektet mod at udforske datadrevne prognosemetoder til en kortsigtet forudsigelse af tilløb til søen.

1.2 Baggrund & nuværende state-of-the-art

Traditionelt er vandføringsprognoser blevet udarbejdet ved hjælp af fysiske modeller som SHE [2, 44]. Disse modeller simulerer hydrologiske processer baseret på detaljerede beskrivelser af terræn, jordbund, vegetation og nedbør. Selvom de tilbyder gode præstationer, er de ofte komplekse og beregningstunge, hvilket gør dem udfordrende at anvende i realtid eller ved hurtig implementering i oplande som f.eks. Horsens opland.

I praksis har man derfor ofte benyttet enklere datadrevne metoder, såsom autoregressive modeller med eksterne forklarende variable (ARX). Disse modeller muliggør løbende opdatering af parametre ved hjælp af online læringsalgoritmer som f.eks. Recursive Least Squares (RLS) [10, 32].

I løbet af det seneste årti er Long Short-Term Memory-netværk (LSTM) blevet etableret som en af de hyppigere brugte metoder indenfor datadrevne nedbør-afstrømningsmodeller. Flere studier har vist, at LSTM-modeller generelt overgår traditionelle metoder på tværs af vejrstationer og klimazoner [18, 9]. Særligt integrationen af attention-mekanismer har vist sig effektiv til at forbedre modellens ydeevne ved ekstreme hændelser [21].

1.3 Projektoversigt

Formålet med projektet er at udforske og sammenligne forskellige tidsseriemodelleringsmetoder til forudsigelse af daglig vandføring til Bygholm Sø baseret på historiske vejr- og hydrologiske data. Målet er at vurdere, hvilke modeller der opnår den bedste balance mellem forudsigelsesnøjagtighed, tilpasningsevne og operationel anvendelighed. Projektet har fokuseret på tre forskningsspørgsmål:


- Hvilke modeller er mest velegnede til kortsigtet forudsigelse af daglig vandføring i Horsens opland?

- Hvordan kan modeller og inputfeatures designes, så de bedst forudsiger ekstreme afstrømningshændelser – og hvordan adskiller deres præstation sig fra gennemsnitlige forhold?
- Hvordan kan hydrologiske og meteorologiske variable kombineres i en forecasting-model for at give den mest nøjagtige forudsigelse af disse hændelser?

2 Oplande & hydrologiske funktioner

For at kunne modellere vandføring i Bygholm sø, er det nødvendigt at forstå de fysiske og hydrologiske mekanismer der styrer afstrømningen i oplandet.

Et opland defineres som det geografiske område, hvor alt nedbør potentielt afstrømmer til ét fælles udløbspunkt, eksempelvis en sø, et vandløb eller havet [35]. Hydrologisk set fungerer oplandet som en naturlig afvandingsenhed, hvor nedbøren enten infiltrerer jorden, fordamper, lagres midlertidigt eller bidrager til overflade- og grundvandsafstrømning. Oplandets funktion kan altså betragtes som et filter og en form for forsinkelsesmekanisme for hydrologiske processer. Fysiske egenskaber som f.eks. topografi, jordbund, arealanvendelse og vegetation, har en afgørende betydning for hvordan og hvor hurtigt denne omdannelse fra nedbør til afstrømning sker [28]. Derfor vil forståelsen af disse forhold være afgørende i enhver model, der forsøger at forudsige vandføring og forebygge potentielle oversvømmelsessituationer.



Figur 1: Bygholm Sø (markeret med blå), samt dets opland (markeret med mørkegrøn). Figuren er lavet i forbindelse med projektet i samarbejde med Horsens Kommune.

De topografiske vandskel, som udgør de naturlige grænser for oplandet i Horsens Kommune er blevet identificeret og kan ses i figur 1. Her er hele oplandet markeret med gul/grøn og Bygholm sø markeret med blå oppe i det nordøstlige hjørne af oplandet. Hele oplandet fungerer som indstrømningsområde til Bygholm Sø, hvor en vandføringsmåler ved Karup Bro (Den nordvestlige ende af søen) står for registrering af den daglige vandføring til søen. I den sydøstlige ende af søen er installeret en sluse, som styrer mængden af vand der løber ud i Bygholm Å. Her løber åen gennem Bygholm park og videre ned gennem Horsens by for til sidst at løbe ud i havet.

Horsens har været meget præget af oversvømmelser i Bygholm park og nærliggende områder, og vil gerne både mindske disse, samt sikre at oversvømmelserne ikke breder sig helt ind til byen. I praksis kunne en forudsigelse af en ekstrem vandføringshændelse bruges til at styre slusen mere proaktivt. Man kunne sænke den i god tid for at skabe ekstra plads i Bygholm Sø og derefter hæve den til sit maksimale for at tilbageholde så meget vand som muligt, givet at resten af å-systemet ikke kan

følge med. Projektet sigter derfor mod at fremstille en model der kan ligge til grund for at forudsige ekstreme vandføringshændelser, og på den måde forberede Horsens mod oversvømmelser.

2.1 Evapotranspiration & nedbørsrespons

Evapotranspiration (ET) er et centralt element i den hydrologiske cyklus og udgør den samlede mængde vand, der fordampes fra jordens overflade samt optages gennem vegetationen. Det er en proces, der afhænger af både meteorologiske forhold og oplandets egenskaber såsom jordtype, vegetationsart og vandtilgængelighed [24]. Forståelsen og korrekt estimering af evapotranspiration er derfor essentiel ved modellering af vandbalancer og nedbørsrespons i oplande.

Evapotranspiration kan opdeles i to hovedkomponenter:

- **Evaporation (E):** Fordampning fra jord og overfladevand.
- **Transpiration (T):** Vandtab fra planter (en del af fotosyntesen).

Summen af disse to betegnes som den aktuelle evapotranspiration (ET_a), mens den potentielle evapotranspiration (ET_p) beskriver den maksimale fordampning under den forudsætning, at der er ubegrænset vandtilgængelighed [4].

I dette projekt anvendes Makkink-formlen til estimering af den potentielle evapotranspiration, da den er velegnet under danske klimaforhold og kræver relativt få inputdata. Formlen blev oprindeligt foreslået af Makkink i 1957 og har siden været anvendt i en række danske studier [30].

Makkink-formlen er givet ved:

$$ET_p = c_1 \cdot \frac{\Delta}{\Delta + \gamma} \cdot \frac{R_g}{\lambda} - c_2 \quad (1)$$

hvor:

- ET_p måler hvor meget vand der fordampes per m^2 per døgn, målt i mm/døgn.
- c_1 er en konstant der justerer skalaen, så formen passer til observeret fordampning under lokale forhold (typisk $c_1 = 0.61$ i Danmark)
- c_2 er en konstant der fungerer som en korrektion for restvarmetransport (typisk $c_2 = 0.12$ mm/døgn)
- Δ er hældningen af mætningsdamptrykskurven [kPa/°C] (Se formel 2 & 3)
- γ er psykrometerkonstanten, som udtrykker forholdet mellem tør- og vådtemperatur [kPa/°C] (Se formel 4)
- R_g er den globale stråling målt som døgnmiddel [MJ/m²/døgn]
- λ er den latente varmes fordampningsenergi (typisk $\lambda \approx 2.45$ MJ/kg)

De nødvendige meteorologiske input for at estimere ET_p via Makkink-formlen er daglige værdier for temperatur og globalstråling. Parameteren Δ udregnes som:

$$\Delta = \frac{4098 \cdot e_{\Delta}(T)}{(T + 237.3)^2} \quad (2)$$

hvor $e_{\Delta}(T)$ er mætningsdamptrykket ved temperatur T (°C)

Mætningsdamptrykket $e_{\Delta}(T)$ kan beregnes ved:

$$e_{\Delta}(T) = 0.6108 \cdot \exp\left(\frac{17.27 \cdot T}{T + 237.3}\right) \quad (3)$$

Parameteren γ udregnes som:

$$\gamma = 0.665 \cdot 10^{-3} \cdot P \quad (4)$$

hvor P er lufttrykket i kPa.

Evapotranspiration varierer meget med årstiden, primært på grund af ændringer i temperatur og solindstråling. I Danmark er ET_p typisk højest i sommermånedene (maj–august), hvor den globale stråling og temperatur topper, mens den er tæt på nul i vintermånedene. Den årlige sum af ET_p i Danmark variere fra ca. 350 til 500 mm, afhængig af lokalitet og den specifikke formel brugt [30].

Oplandets respons på nedbør afhænger af den aktuelle jordfugtighed og den forudgående evapotranspiration. Hvis jorden er mættet, resulterer nedbør i hurtig overfladeafstrømning [13]. Er jorden derimod tør, vil nedbøren primært blive absorberet, indtil jorden når sin markkapacitet¹. Dette skaber et ikke-lineært respons, hvor nedbørens effekt på afstrømning afhænger af både intensitet og forudgående forhold.

I praksis betyder dette, at to identiske nedbørshændelser kan resultere i meget forskellig afstrømning afhængigt af, om oplandet befinder sig i en høj eller lav ET -periode [33]. Derfor udgør ET altså en meget vigtig variabel i vurderingen af vandføring og i træning af modeller, der baserer sig på historiske data, da ET indirekte forklarer variationer i afstrømningsrespons gennem året.

¹Markkapacitet defineres som jordens vandindhold efter vandmætning, når nedsivning er ophørt (normalt efter to dage)

3 Tidsrækkeanalyse

Tidsrækkeanalyse handler om at analysere og modellere data, der er observeret over tid, hvor rækkefølgen af observationerne er central. Det adskiller sig fra klassisk statistisk analyse ved, at observationerne ofte er korrelerede i tid, hvilket kræver særlige modeller og metoder. Formålet med tidsrækkeanalyser er ofte, at forstå det underliggende system, lave prognoser for fremtidige værdier, eller anvende modellerne til kontrol og beslutningsstøtte i dynamiske systemer [22].

Et centralt aspekt ved tidsrækkeanalyse er, at de observerede data kan betragtes som én realisering af en stokastisk proces - altså som et tilfældigt udfald inden for processens udfaldsrum. Fokus er typisk på lineære modeller, især fordi de tillader anvendelse af klassiske metoder fra både tids- og frekvensdomænet. I praksis forekommer tidsrækker i mange domæner: fra økonomiske indikatorer, valutakurser og tekniske målinger til naturlige og komplekse processer. [45].

Formålet med dette afsnit er at præsentere de vigtigste begreber og metoder inden for tidsrækkeanalyse med fokus på stationaritet, autokorrelation, og autoregressive modeller. De valgte modeller er især relevante i sammenhænge, hvor det antages, at systemets dynamik kan beskrives som en lineær relation over tid med eller uden eksterne påvirkninger.

3.1 Stokastiske processer

En stokastisk proces betegner en samling af tilfældige variable, $\{Y_t\}_{t \in \mathbb{Z}}$, indekseret ved tid t . I konteksten af tidsrækkeanalyse er der tale om en diskret-tids stokastisk proces, hvor tiden udvikler sig i diskrete trin (fx timevis eller dagligt), og hvor rækkefølgen af observationer er afgørende [45]. Formelt beskrives processen som:

$$\{\dots, Y_{t-1}, Y_t, Y_{t+1}, \dots\} = \{Y_t\}_{t=-\infty}^{\infty}$$

hvor hvert Y_t er en tilfældig variabel defineret på et fælles sandsynlighedsrum.

Som førnævnt, vil man i praksis kun observere én realisering af denne proces over en endelig horisont T , hvilket giver anledning til den observerede tidsrække:

$$\{Y_1 = y_1, Y_2 = y_2, \dots, Y_T = y_T\} = \{y_t\}_{t=1}^T$$

Formålet med at modellere en stokastisk proces er at beskrive den underliggende sandsynlighedsstruktur, som antages at ligge til grund for de observerede data. Dette muliggør blandt andet estimering af strukturelle egenskaber som varians, autokorrelation og andre mål for afhængighed over tid.

I modsætning til klassisk stikprøvet teori, hvor observationer antages uafhængige og identisk fordelte (i.i.d.), har observationer i en tidsrække ofte en indbygget struktur. Derfor er det nødvendigt at gøre antagelser om den fælles adfærd for de stokastiske variable $\{Y_t\}$, så man kan behandle processen analytisk - fx ved at anvende metoder i stil med dem, man bruger i tilfældige stikprøver fra en population [45].

3.2 Tidsrækkemodeller

En tidsrække kan modelleres ved hjælp af lineære modeller, som beskriver afhængigheden mellem observationer over tid. Blandt de mest anvendte modelklasser er autoregressive (AR), moving average (MA) og kombinationer heraf såsom ARMA og ARIMA. Disse modeller benyttes til at identificere, forstå og forudsige dynamikken i den underliggende stokastiske proces.

Ved valg af modeltype anvendes autokorrelations- og partial autokorrelationsfunktioner (ACF & PACF) som diagnostiske værktøjer, idet de forskellige modeltyper efterlader karakteristiske signaturer i disse funktioner [45].

3.2.1 Autoregressive modeller

En autoregressiv model af orden p , betegnet $AR(p)$, udtrykker den aktuelle observation som en lineær kombination af de p foregående observationer plus et stokastisk støjled:

$$Y_t = \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_p Y_{t-p} + \varepsilon_t$$

hvor ε_t er hvid støj med middelværdi nul og konstant varians og ϕ_p er AR-koefficienterne, som bestemmer vægten af de forrige p observationer [22].

Modellen antager, at al afhængighed i data kan forklares gennem egne tidligere værdier. For AR-processer anvendes typisk PACF til identifikation af antal lags som skal tilføjes til modellen. Når man tegner PACF-funktionen, vil alle søjler for lag $> p$ ligge tæt på nul. Derfor kan man aflæse den maksimale lagorden p direkte på PACF-grafen. Man vælger derfor det største p , hvor søjlen stadig er tydeligt forskellig fra nul, og alle søjler derefter falder ind under signifikansgrænsen [45].

Udover AR-modeller, findes også moving average (MA) modeller, som i stedet bygger på tidligere fejllid i stedet for tidligere værdier. MA-modeller bruges ofte i kombination med AR-komponenter, de inddrages dog ikke i dette projekt.

3.2.2 Eksogene input

En udvidelse af de klassiske tidsrækkemodeller er at inkludere eksterne forklarende variable, også kaldet eksogene input. Dette gør det muligt at modellere situationer, hvor output ikke alene afhænger af tidligere værdier af sig selv, men også af andre relevante påvirkninger. En typisk tilgang er ARX-modellen (Autoregressive with Exogenous inputs), hvor man tilføjer samtidige eller forsinkede eksterne variable X_t til en AR-model:

$$Y_t = \sum_{i=1}^p \phi_i Y_{t-i} + \sum_{j=0}^r \beta_j X_{t-j} + \varepsilon_t. \quad (5)$$

Her udgør ε_t en hvid støj-proces, og parametrene β_j kvantificerer effekten af de eksterne input på outputvariablen [3].

ARX-modeller anvendes især i situationer hvor sammenhængen mellem input og output er vigtig. Det gælder f.eks. i vores tilfælde, hvor vandføring kan afhænge af både tidligere afstrømning og tidligere inputværdier som nedbør og temperatur. Inklusionen af eksogene variable forbedrer modellens forklaringskraft og gør det muligt at forudsige hvordan systemet reagerer på ydre påvirkninger, hvilket er vigtigt i praksis, når man træffer beslutninger eller laver pålidelige prognoser. [3].

3.3 Recursive Least Squares (RLS)

I forbindelse med anvendelsen af tidsrækkemodeller til prognoser for vandføring til Bygholm Sø, er der behov for metoder, der kan tilpasse sig løbende ændringer i datastrukturen – eksempelvis forårsaget af årstidsskift, ændringer i jordmætning eller vejrekstremer. I den ARX-lignende model fra ligning (5) estimeres både de autoregressive parametre ϕ og koefficienterne for de eksogene input β . For at kunne opdatere disse parametre effektivt benyttes Recursive Least Squares (RLS). RLS

er særligt velegnet til systemer med dynamisk karakter, hvor modellen skal justeres løbende uden at gentrænes på hele datasættet, og gør det muligt at opretholde præcise forecasts i takt med at nye observationer bliver tilgængelige [38].

3.3.1 Formål & grundprincip

Recursive Least Squares (RLS) er en metode til løbende estimering af parametre i lineære modeller. Den bygger på det klassiske Ordinary Least Squares (OLS), som kræver hele datasættet til rådighed og hurtigt bliver beregningstung ved store datamængder [36]. RLS adskiller sig ved at opdatere parameterestimatet trin for trin, hver gang en ny observation bliver tilgængelig. Det gør metoden særligt velegnet til online forecasting, som er centralt i mange tidsrække modeller.

Den lineære model, som RLS anvendes på, har typisk formen:

$$y_t = \mathbf{x}_t^\top \boldsymbol{\theta}_t + \varepsilon_t \quad (6)$$

hvor:

- y_t er den afhængige variabel (fx vandføring),
- $\mathbf{x}_t$ er en vektor af forklarende variable (fx tidligere vandføring, nedbør, temperatur m.m.),
- $\boldsymbol{\theta}_t$ er parametervektoren, som skal estimeres,
- ε_t er et støjled, antaget at være hvid støj med middelværdi nul og konstant varians [26].

3.3.2 RLS med forgetting factor

En udvidelse af RLS er brugen af en forgetting factor, betegnet $\lambda \in (0, 1]$, som kontrollerer, hvor hurtigt ældre data mister betydning i estimatet. Når forgetting factor sættes til $\lambda = 1$, svarer algoritmen i praksis til en rekursiv version af OLS, hvor alle tidligere observationer vægtes lige højt. Hvis $\lambda < 1$, får ældre observationer gradvist mindre vægt, hvilket gør modellen mere adaptiv og i stand til at reagere hurtigere på ændringer i datastrukturen.

Vægten af en observation k tidsskridt tilbage er givet ved λ^k . Det betyder, at ældre data eksponentielt mister indflydelse på parameterestimatet. Denne mekanisme er nyttig i ikke-stationære systemer, hvor relationerne mellem variablerne kan ændre sig over tid [26].

3.3.3 Algoritme

RLS-algoritmen estimerer parametre løbende ved at minimere en vægtet sum af kvadrerede fejl, hvor nyere observationer vægtes højere end ældre. Den funktion, der minimeres, er:

$$J_t(\boldsymbol{\theta}) = \sum_{i=1}^t \lambda^{t-i} (y_i - \mathbf{x}_i^\top \boldsymbol{\theta})^2 \quad (7)$$

Her er $\lambda \in (0, 1]$ forgetting factoren, der styrer hvor hurtigt ældre data mister indflydelse.

Algoritmen starter med at initialisere parametervektoren med nul og definere en høj start-usikkerhed:

$$\boldsymbol{\theta}_0 = \mathbf{0}, \quad \mathbf{P}_0 = \delta \cdot \mathbf{I} \quad (8)$$

Her er δ en stor konstant, og $\mathbf{I}$ er identitetsmatricen. En høj initial usikkerhed ($\delta \gg 0$) gør, at modellen i begyndelsen er meget åben for nye informationer og derfor tilpasser sig hurtigt.

Når en ny observation kommer ind, opdateres modelparametrene i fire trin:

1. **Beregn gain-vektor:**

$$\mathbf{K}_t = \frac{\mathbf{P}_{t-1} \mathbf{x}_t}{\lambda + \mathbf{x}_t^\top \mathbf{P}_{t-1} \mathbf{x}_t} \quad (9)$$

Gain-vektoren fungerer som en læringsrate, der bestemmer hvor meget de nye data påvirker modellen. Jo større usikkerhed, jo mere får den nye data lov at justere modellen.

2. **Beregn forudsigelsesfejl:**

$$e_t = y_t - \mathbf{x}_t^\top \boldsymbol{\theta}_{t-1} \quad (10)$$

Fejlen mellem den faktiske observation og modelens forudsigelse udregnes.

3. **Opdater parametre:**

$$\boldsymbol{\theta}_t = \boldsymbol{\theta}_{t-1} + \mathbf{K}_t e_t \quad (11)$$

Parametrene opdateres i retning af forudsigelsesfejlen, skaleret af gain-vektoren $\mathbf{K}_t$.

4. **Opdater usikkerhedsmatrix:**

$$\mathbf{P}_t = \frac{1}{\lambda} \left(\mathbf{P}_{t-1} - \mathbf{K}_t \mathbf{x}_t^\top \mathbf{P}_{t-1} \right) \quad (12)$$

Usikkerhedsmatricen udtrykker den aktuelle usikkerhed i parametrene. Usikkerheden i modellen reduceres efterhånden som flere observationer behandles.

Algoritmen gør det muligt at opdatere modellen løbende, uden at hele datasættet skal gemmes. I starten, hvor usikkerheden er høj, reagerer modellen hurtigt og lærer aggressivt. Senere, når usikkerheden er reduceret, bliver opdateringerne mere forsigtige, hvilket beskytter mod overfitting [38].

RLS er særligt velegnet til hydrologiske systemer med tidsvarierende dynamik, som det er tilfældet i Horsens opland, hvor inputforhold som nedbør ændrer sig over tid. Metoden er adaptiv, idet parametrene tilpasses løbende, så modellen kan reagere på skiftende forhold som ændringer i nedbørsmønstre og sæsonvariationer. Derudover er metoden robust, da den ved hjælp af glemselsfaktoren λ nedtoner ældre observationer, så modellen ikke forbliver fastlåst i tidligere systemtilstande, der ikke længere er relevante.

Kombinationen af en lineær tidsrække-model og RLS giver dermed en løsning, der både er enkel at implementere og i stand til at tilpasse sig løbende. Det gør metoden særligt anvendelig i dette projekt, hvor der er behov for så præcise estimater som muligt, lav beregningstid og fleksibilitet over for ændringer i systemets dynamik [16].

4 Long Short-Term Memory (LSTM)

Notation

For overskuelighedens skyld anvendes følgende notation i dette afsnit:

- $x_t \in \mathbb{R}^n$: input-vektoren ved tidspunkt t .
- $h_t \in \mathbb{R}^m$: hidden-tilstand (vektor der repræsenterer LSTM-cellens interne hukommelse) ved tidspunkt t .
- $C_t \in \mathbb{R}^m$: cell state ved tidspunkt t .
- For hver gate (forget, input, output) samt til opdatering af cell state:
 - $W_* \in \mathbb{R}^{m \times (m+n)}$: vægtmatrice, som løbende bliver opdateret under træning.
 - $b_* \in \mathbb{R}^m$: bias-vektor, som løbende bliver opdateret under træning.
 - $\sigma(\cdot)$: sigmoid-funktion,

$$\sigma(z) = \frac{1}{(1 + e^{-z})}$$

- $\tanh(\cdot)$: hyperbolsk tangent-funktion,

$$\tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$$


- $[h_{t-1}, x_t]$: vektorsammensætning (“concatenation”) af h_{t-1} og x_t til én vektor.

4.1 Recurrent Neural Network & problemet med lange sekvenser

For at kunne forklare Long Short-Term Memory (LSTM) modeller, er det nødvendigt først at forstå deres udgangspunkt. Recurrent Neural Networks (RNNs) blev udviklet til at håndtere sekventielle data som sprog, tidsserier og videoer, hvor konteksten i tidligere inputs er vigtig for forståelsen af nuværende input. Deres styrke ligger i den interne kobling, som gør det muligt at huske tidligere information i en skjult tilstand, der opdateres ved hvert tidsskridt [37].

I praksis viser RNNs dog alvorlige begrænsninger, især når det gælder lange sekvenser. Når antallet af tidsskridt øges, bliver det næsten umuligt for netværket at bevare information fra starten af sekvensen. Dette skyldes det såkaldte exploding/vanishing gradient problem [12]. Under træning med backpropagation gennem tid kan gradienterne enten blive ekstremt små og forsvinde, eller vokse ukontrolleret og eksplodere. I begge tilfælde forhindrer det effektiv læring.


Som vist i Figur 2, fungerer et RNN ved at tage både det aktuelle input x_t og den tidligere skjulte tilstand h_{t-1} som input og producere en ny skjult tilstand h_t . Denne mekanisme genbruges ved hvert tidsskridt. Problemet opstår, når afhængigheder på tværs af mange tidsskridt skal læres – for eksempel hvis man skal huske noget fra dag 1 for at kunne forudsige noget på dag 50. I disse tilfælde er den tilbageførte gradient enten blevet for lille (og dermed ubrugelig) eller for stor (og dermed ustabil) [12].



Figur 2: Visualisering af et Recurrent Neural Network (RNN). Figur gengivet fra [27]


4.2 Idéen bag LSTM

LSTM blev i 1997 introduceret som en løsning på dette problem [12]. I stedet for én enkelt hukommelsessti, som man ser i RNNs, opdeler LSTMs informationen i både langtidshukommelse (cell state C_t) og korttidshukommelse (hidden state h_t). Hele den interne struktur af en LSTM-celle kan ses i Figur 3, hvor der findes fire lag i modsætning til det ene lag i RNN-cellen fra Figur 2. For at få et bedre indblik i hvad de forskellige interaktioner i figurene helt konkret betyder, se Bilag 23



Figur 3: Struktur af en LSTM celle, hvor hver interaktion er påvist. Figur gengivet fra [27]

Den centrale idé bag LSTMs er, at cell state løber næsten uændret gennem netværket, kun modificeret af nøje kontrollerede gates – og uden direkte vægte [27]. Denne struktur tillader, at vigtig information kan flyde over mange tidsskridt uden at miste sin styrke eller eksplodere, se Figur 4.



Figur 4: Den centrale cell state i en LSTM tillader langtidshukommelse uden eksploderende/forsvindende gradient. Figur gengivet fra [27]


4.2.1 Forget gate

Et LSTM-netværk består af fire primære komponenter: forget gate, input gate, cell state update og output gate. Hver komponent har en specifik rolle i at styre informationsflowet gennem tid, og den første af disse er forget-gaten.

Forget-gaten bestemmer, hvor meget af den tidligere cell state C_{t-1} der skal bevares og hvor meget der skal glemmes. Dette gøres ved at kombinere den tidligere skjulte tilstand h_{t-1} og det nuværende input x_t , hvorefter resultatet sendes gennem en sigmoid-funktion:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (13)$$

Den resulterende værdi f_t er et tal mellem 0 og 1 for hver dimension i cell state. Et f_t tæt på 1 betyder, at informationen i den tilsvarende del af C_{t-1} bevares næsten fuldt ud, mens et f_t tæt på 0 medfører, at informationen glemmes. På den måde lærer netværket selv, hvad der er vigtigt at huske, og hvad der kan ignoreres [31, 27]. Processen er visualiseret i Figur 5.



Figur 5: Forget gate. Figur gengivet fra [27]


4.2.2 Input gate & potentiale til ny hukommelse:

Input-gaten styrer, hvilken ny information der skal føjes til den nuværende cell state. Det sker i to trin: Først beregnes input-gaten i_t , som afgør, hvor meget af den nye information der skal tillades ind. Derefter beregnes en kandidat til ny hukommelse $\tilde{C}_t$, som repræsenterer de mulige nye værdier, der kan tilføjes til cellen [31, 27]. Det er beskrevet ved:

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (14)$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \quad (15)$$

Ligning 14 bruger en sigmoid-aktivering, som sikrer, at i_t bliver et tal mellem 0 og 1 — altså en vægt, der bestemmer hvor meget af den nye kandidat-hukommelse skal integreres. Ligning 15 anvender en tanh-aktivering for at generere de potentielle nye indholdsværdier i området $[-1, 1]$. Kombinationen af disse to størrelser bruges i næste trin til at opdatere cell state [31, 27]. Dette er også illustreret i Figur 6.




Figur 6: Input gate og ny potentiel hukommelse. Figur gengivet fra [27]

4.2.3 Opdatering af cell state:

Når forget-gaten og input-gaten har vurderet, hvad der skal glemmes, og hvad der skal tilføjes, opdateres selve cell state — altså netværkets langtidshukommelse. Denne opdatering sker ved at kombinere to komponenter: (1) den tidligere cell state C_{t-1} , reduceret i henhold til forget-gatens vægt f_t , og (2) den nye kandidat-hukommelse $\tilde{C}_t$, skaleret med input-gatens vægt i_t . Det udtrykkes matematisk som:

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t \quad (16)$$

Dette gør det muligt for netværket både at fastholde vigtige historiske informationer og samtidigt tilføje ny læring, afhængigt af konteksten. Netop denne kombination er kernen i LSTM'ens evne til at håndtere lange sekvenser, uden at gradienter forsvinder eller eksploderer [31, 27]. Processen er illustreret i Figur 7.



Figur 7: Opdatering af cell state. Figur gengivet fra [27].

4.2.4 Output gate & ny hidden state:

Efter at cell state C_t er blevet opdateret, skal LSTM-cellen bestemme, hvad der skal sendes videre som output. Dette styres af output-gaten, som regulerer, hvilken del af den opdaterede cell state der skal eksponeres til det næste tidsskridt og/eller det næste lag i netværket.

Først beregnes output-gateværdien o_t med en sigmoid-funktion, der afhænger af den tidligere skjulte


tilstand h_{t-1} og det aktuelle input x_t :

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (17)$$

Dernæst sendes den opdaterede cell state C_t gennem en tanh-aktiveringsfunktion, som skalerer værdierne til intervallet $[-1, 1]$. Dette resulterende signal moduleres så af o_t , så kun udvalgte informationer slipper igennem:

$$h_t = o_t * \tanh(C_t) \quad (18)$$

Resultatet h_t fungerer både som output fra den nuværende LSTM-celle og som skjult tilstand til næste tidsskridt. Denne mekanisme gør det muligt for LSTM'en at kontrollere, hvilke dele af dens interne tilstand der skal påvirke fremtidige beregninger [31, 27]. Processen er illustreret i Figur 8.



Figur 8: Output gate. Genererer h_t baseret på C_t . Figur gengivet fra [27].

Ved at separere langtidshukommelse og korthukommelse, samt ved at styre informationsflowet med gates, formår LSTM-netværker at løse de problemer som plager traditionelle RNNs. Ved hjælp af sigmoid- og tanh-aktiveringer kan netværket finjustere, hvad der skal glemmes, hvad der skal læres, og hvad der skal videreføres. Dette gør LSTM til en robust arkitektur for sekventielle data, hvor langvarige afhængigheder er vigtige.

5 Dataanalyse & eksplorativ visualisering

For at få et overblik af datasættet som arbejdes med, blev der foretaget en indledende analyse af dets struktur og kvalitet. Fokus var særligt på tidsserien for vandføring, men nedbør og temperatur inddrages også som centrale forklarende variable [29]. Visualiseringerne danner grundlag for forståelsen af de hydrologiske mønstre og eventuelle problemer der kunne finde sted i data.

5.1 Datakvalitet


Datakvaliteten for de tre variable beskrevet i afsnittet kan ses i Tabel 1. Data blev som førnævnt hentet direkte fra DMI og Vandportalen, hvor vandføring kun fandtes i daglig opløsning. Derfor blev de forklarende variable transformeret fra timevis opløsning til daglig opløsning for at matche vandføring. Herefter var der meget få 'missing values', som blev interpoleret for at sørge for en kontinuerlig tidsrække. For at se en mere detaljeret beskrivelse af behandlingen af alle variable, se Bilag 3 & 22. Hele github repository kan også findes her: [nicolaigarder/Forecasting-water-inflow](https://github.com/nicolaigarder/Forecasting-water-inflow) [11].

Variabel	Antal manglende	Andel manglende (%)
Timevise data (før behandling)		
Gennemsnitstemperatur	5998	2.98
Nedbørsmængde	8483	4.21
Vandføring	–	–
Daglige data (før interpolering)		
Gennemsnitstemperatur	150	1.87
Nedbørsmængde	0	0
Vandføring	0	0
Daglige data (efter behandling)		
Gennemsnitstemperatur	0	0
Nedbørsmængde	0	0
Vandføring	0	0

Tabel 1: Oversigt over missing values før og efter databehandling for data visualiseret i afsnittet

5.2 Overblik over datasættet & tidsserier


Datasættet der arbejdes med er hentet direkte fra DMI [6] og Vandportalen [34]. Vandføringsdata hentet fra Vandportalen fandtes kun som døgnmidler målt i l/s. Data fra DMI – som ellers findes i timevis opløsning – er derfor blevet transformeret til også at være daglige målinger (For mere detaljeret beskrivelse af transformation, se bilag 3). Data er udtrukket fra perioden 2002.01.01 – 2023.12.31, hvor et overblik af hele tidsserien kan ses i Figur 9.



Figur 9: Tidsserieplot af daglig vandføring (l/s) over hele perioden.

Tidsserien viser, hvordan vandføringen varierer fra 2002 til 2023. Man kan i plottet observere en generel sæsonmæssig cyklus, hvor vandføringen typisk er højere i vinterhalvåret og lavere i sommerhalvåret.


For at få et bedre overblik af hvordan vandføring fordeler sig for hvert år, ses i Figur 10 vandføringens variation i løbet af året, når man sammenfatter alle år til ét år. Plottet viser fordelingen af de 21 observationer der har været for hver dag på året.



Figur 10: Plot af fordelingen af den daglige vandføring (l/s) fordelt over dag på året. Her ses både middelværdi, median og 25-75 percentilerne for hver dag på året.


Plottet er bygget op, så at den mørkerøde linje repræsenterer medianen af data for hver dag på året, samt et lysere bånd som indikerer hver dags 25-75 percentil. Derudover er den grå stiplede linje den gennemsnitlige værdi for hver dag på året. Det er tydeligt, at både medianen og den gennemsnitlige vandføring er højest i vinterperioden (november til marts), hvor nedbør og mindre fordampning kan føre til højere afstrømning. Vandføringen er derfor ofte lavere i sommermånederne, hvor tørkeperioder og høj fordampning kan sætte sit præg.

Man ser også på kvartilbåndet, at spredningen i data er markant større om vinteren, hvilket tyder på en større variation i vandføring i den periode. Gennem hele året ligger middelværdien over medianen, hvilket indikerer en højreskæv fordeling. Der forekommer altså enkelte dage med meget høj vandføring, som trækker gennemsnittet op (Dette ses også i fordelingen af vandføring i bilag 26)



Figur 11: Plot af det gennemsnitlige daglige nedbør (mm/døgn) fordelt over dag på året.

For også at få et indblik i hvordan nedbør varierer i løbet af et år, kan man i Figur 11, se et lignende plot for nedbør, som sammenfatter nedbøren på tværs af alle år og viser fordelingen for hver dag på året. Her ses medianen til at ligge mellem 0-2 mm/døgn, hvor den er lavest og med mindste spredning i løbet af foråret. I løbe af både efteråret og vinteren ses den klart største spredning med kvartilerne over de 5 mm/døgn flere gange. På samme måde som i fordelingen af vandføring, findes den gennemsnitlige nedbør til at ligge en del højere end medianen. Det tyder derfor også på at nedbør bærer præg af en meget højreskæv fordeling, hvilket også bliver bekræftet i af histogrammet i bilag 27



Figur 12: Plot af den gennemsnitlige daglige temperatur (°C) fordelt over dag på året.

På samme måde som med vandføring og nedbør, ses fordelingen af den gennemsnitlige daglige tempe-

ratur for hver kalenderdag i Figur 12. Her ses en stor variation i både median og middelværdi mellem vinter- og sommermåneder som i alt strækker sig fra omkring 0°C til omkring 17°C . Spredningen af data ses også værende en smule større i vintermånederne sammenlignet med sommermånederne. Her ses middelværdi og median dog til at ligge nogenlunde ens i løbet af året, hvilket tyder på at temperaturen er normalfordelt.

Hvis man sammenligner de tre fordelingsplots, ser man hurtigt, at selv med nogenlunde sammen mængde nedbør i løbet af sommer og vintermånederne, ses vandføringen til at være meget lavere og mere stabil fra april-oktober, hvilket også er her at temperaturen har sine højeste værdier. Det tyder derfor på at temperatur (herigennem fordampning) i hvert fald spiller en rolle i at reducere den mængde nedbør, der ender som afstømning i sommerhalvåret.


5.3 Ekstreme hændelser: Sammenhængen mellem nedbør & vandføring

Da målet med projektet er at kunne forudsige vandføring med henblik på at kunne forhindre ekstreme hændelser i Horsens Kommune, er det vigtigt også at forstå hvordan og i hvor høj grad nedbør påvirker vandføringen. Bilag 24 giver et detaljeret indblik i de tre største vandførings-hændelser i dataperioden. I alle tilfælde peaker vandføringen omtrent ét døgn efter den største nedbørsmængde.

Den systematiske forsinkelse mellem nedbør og afstrømning peger på en reagerende men ikke øjeblikkelig hydrologisk respons i oplandet. Som udgangspunkt vil man tro at de største vandførings-hændelser skulle være på baggrund af en stor mængde nedbør. Kigger man dog på den andenstørste vandføringshændelse den 1. marts 2007, viser den sig ikke at være på baggrund af en ekstrem mængde nedbør (≈ 10 mm). At en stor regnmængde ikke nødvendigvis fører til en stor vandføring antyder, at andre faktorer som f.eks. jordfugtighed, temperatur og grundvandsstand også kan være styrende.

Derudover viser det sig også at være tilfældet, at ekstreme regnvejrsk dage ikke nødvendigvis fører til ekstreme vandføringer. Ser man på de tre største nedbørshændelser i perioden, er der ingen af disse ekstreme regndage der fører til tilsvarende ekstreme vandføringshændelser (se bilag 25)

Den største hændelse fandt sted den 25. juli 2015, hvor der blev registreret 52,7 mm nedbør. Dette medførte dog kun et moderat vandføring på omkring 2000 l/s. Det tyder på, at oplandet opfører sig komplekst og ikke reagerer lineært på kraftig nedbør, hvilket tyder på at rene lineære modeller højst sandsynligt ikke er tilstrækkelige til at beskrive systemets dynamik.




Figur 13: Lagged kryds-korrelation mellem nedbør (mm/døgn) og vandføring (døgnmiddel) fordelt på hver måned. Lagged for 0–10 dage.

I figur 13, ses et korrelationsplot for lag 0–10 dage, opdelt efter hver måned. Her ses at nedbør i især januar, februar og juni har en høj korrelation med vandføringen på over 0.5 ved lag 1. Helt generelt, ligner det at der er en lille tendens til at forårmånederne ligger lavest og vintermånederne højest, hvilket understøtter de tidligere observationer.

For næsten alle måneder gælder derudover, at korrelationen toppe ved lag = 1 døgn med en korrelation mellem 0.34 og 0.55, hvilket i næsten alle tilfælde er næsten dobbelt så højt som den samtidige korrelation som ligger mellem 0.15 og 0.4. Herefter falder korrelationen monotont og når under 0.15 for alle måneder efter 10 dage. Resultatet bekræfter det visuelle billede fra Figur 24 og indikerer at størstedelen af afstrømningsresponsen er koncentreret inden for de første 48 timer efter en nedbørshændelse.

5.4 Partial autokorrelation & lagget vandføring



Figur 14: Partial autokorrelationsplot for vandføring med lags op til 10 dage.

Ved analyse af tidsserier er det vigtigt at forstå, i hvor høj grad en observation afhænger af sine forgængere. Partial autokorrelationsfunktionen (PACF) bruges til at identificere direkte sammenhænge mellem observationer med forskellige lags, når effekten fra mellemliggende led er fjernet. For vandføringen ses en signifikant autokorrelation ved lag 1 og 2, hvilket indikerer, at de seneste dages vandføring har en direkte effekt på den nuværende værdi. Efter lag 2 falder korrelationen hurtigt og nærmer sig nul, hvilket tyder på, at en autoregressiv model med lav orden vil være tilstrækkelig til at fange den lineære dynamik i tidsserien.

6 Metode

I dette afsnit beskrives de modeller og metoder, der anvendes til at forudsige vandføring. To forskellige typer modeller undersøges: en klassisk regressionsmodel ARX(1) (som i løbet af projektet også vil blive refereret til som RLS-modellen) og et LSTM netværk. Som baseline anvendes en simpel persistensmodel. Udvælgelse af inputvariabler sker ved hjælp af forward selection [39]. En meget vigtig forudsætning i dette projekt er, at der benyttes allerede observerede (og derfor faktiske) fremtidige værdier for vejrdato. Modellerne antager derfor, at der er perfekte vejruddsigter til rådighed. Dette skal tages i betragtning, når modellernes præstation senere vurderes, da det ikke afspejler en realistisk forecasting-situation.

6.1 Variabeludvælgelse & forecast-opsætning

Ved opstilling af modellerne er der anvendt forward selection til at udvælge de mest relevante inputvariabler. Forward selection er en trinvis metode til variabeludvælgelse, hvor modellen starter uden nogen forklarende variable og gradvist udvides. På hvert trin tilføjes den variabel, som forbedrer modellens præstation mest ifølge en valgt evalueringsmetrik, i dette projekt Root Mean Squared Error (RMSE).

Formelt kan dette skrives som:

$$x_j = \arg \min_{x \in \mathcal{X} \setminus \mathcal{S}} \text{RMSE}(\mathcal{S} \cup \{x\})$$

hvor $\mathcal{X}$ er mængden af alle mulige inputvariable, $\mathcal{S}$ er de allerede udvalgte variable, og x_j er den næste variabel, der tilføjes til modellen.

Processen gentages, indtil tilføjjelsen af nye variable ikke længere forbedrer modellens præstation. Metoden bruges for at sikre en model med passende kompleksitet og for at undgå overfitting ved kun at inkludere de mest informative inputvariable [25].

Derudover skelnes der i projektet mellem online og offline forecasting. Offline forecasting indebærer, at hele datasættet er tilgængeligt ved træning og forudsigelse, og modellen justeres ikke løbende. Online forecasting derimod forudsætter, at data ankommer løbende over tid, og modellen opdateres i takt med nye observationer. Dette stiller særlige krav til modellens opbygning og træningsstrategi og afspejler mere realistiske anvendelsesscenarier, hvor fremtidige observationer endnu ikke er tilgængelige [17].

6.2 Baseline: Persistensmodel

Persistensmodellen er en ikke-parametrisk metode, der ofte anvendes som baseline i tidsrækkeanalyse [15]. Modellen bygger på antagelsen om, at systemets tilstand i det næste tidsstep er uændret i forhold til det seneste observerede. For en given responsvariabel y_t , formuleres persistensmodellen matematisk som:

$$\hat{y}_{t+k} = y_t \tag{19}$$

hvor $\hat{y}_{t+k}$ er forudsigelsen af vandføringen ved tid $t + k$, baseret udelukkende på observationen ved tid t , og k er horisonten. Der foretages ingen estimatberegninger eller parametertræning, hvilket gør modellen ekstremt simpel og let at implementere.

Trods sin simplicitet kan persistensmodellen være konkurrencedygtig i situationer med høj tidslig autokorrelation, især over korte forudsigelsehorisonter. Den fungerer derfor som et nyttigt referencpunkt for at vurdere præstationsforbedringer ved mere avancerede modeller.

6.2.1 Implementering i dette Projekt

Persistence-modellen er anvendt som en baseline for forecasting af daglig vandføring til Bygholm Sø. For hver forecast-horisont $k \in \{1, 2, 3, 4, 5\}$ er persistence forecastet defineret ved at anvende observationen fra dagen før forecast-dagen.

6.3 Model 1: ARX-model

Til modellering og forudsigelse af vandføringen ved Bygholm sø er der i dette projekt anvendt en autoregressiv model med eksogene input (ARX), specifikt i form af en online RLS-implementering. Dette valg muliggør løbende opdatering af modelparametre, hvilket er velegnet til ikke-stationære datasæt, som f.eks. hydrologiske tidsserier påvirket af skiftende vejrforhold og sæsonvariationer [20]. Modellen estimerer en lineær sammenhæng mellem vandføring og forklarende variable som tidligere vandføring og nedbør, samt et udvalg af andre meteorologiske variable.

6.3.1 Modelopstilling via forward selection

Modellens struktur blev gradvist udvidet med relevante inputvariable gennem en forward selection-proces kombineret med hyperparameteroptimering. For at sikre at modellen ikke trænede på de data som der senere blev evalueret på, blev datasættet delt op i et trænings-, validerings- og testsæt (60/20/20), i tidslig rækkefølge, så at træningssættet er de første år og testsættet er de sidste. Udgangspunktet for modellen var:

- Et konstantled (bias),
- Lag-1 af den afhængige variabel, y_{t-1} ,
- Et lavpasfilteret nedbørsignal forskudt k dage frem.

Herefter blev yderligere inputvariable udvalgt én ad gangen gennem en iterativ forward selection-proces. Formålet var at reducere fejl i k -dags forudsigelser, og på hvert trin blev følgende gjort:

- Hver kandidatfeature blev afprøvet sammen med den aktuelle model.
- For hver feature blev en grid search gennemført over kombinationer af to hyperparametre:
 - Forgetting-faktoren $\lambda \in \{0.9, 0.95, 0.99\}$
 - Lavpasfilterets vægt $a_1 \in \{0.4, 0.5, 0.6, 0.7, 0.8, 0.9\}$
- Valget blev baseret på laveste RMSE i en fast valideringsperiode.

Processen blev gentaget, indtil ingen yderligere forbedring blev opnået. Den endelige model for $k = 1$ tilføjede følgende to features:

- **Nedbørsvarighed:** Antal minutter det har regnet i løbet af det seneste døgn målt i minutter.
- **Strålingsintensitet:** Gennemsnitlige strålingsintensitet målt i W/m^2

De bedste hyperparametre kombineret med de to features blev:

$$\lambda = 0.95 \quad \text{og} \quad a_1 = 0.5 \quad (20)$$

Den endelige model kan derfor beskrives som:

$$\hat{y}_t = \theta_0 + \theta_1 \cdot y_{t-1} + \theta_2 \cdot \tilde{p}_t + \beta_1 \cdot X_1 + \beta_2 \cdot X_2 \quad (21)$$

hvor:

- $\hat{y}_t$ er den estimerede vandføring på dag t ,
- y_{t-1} er vandføring dagen før,
- $\tilde{p}_t$ er lavpasfiltreret nedbør på dag t (EWMA med $a_1 = 0.5$),
- $X_1 = \text{Nedbørsvarighed}_t$
- $X_2 = \text{Strålingsintensitet}_t$

Modelparametrene $\theta_0, \theta_1, \theta_2$ & β_1, β_2 opdateres løbende ved hjælp af RLS med $\lambda = 0.95$

6.3.2 Implementering & online forudsigelse

Der blev opsat fem separate modeller – én for hvert forecast-horisont $k \in \{1, 2, 3, 4, 5\}$. For hver horisont predikterede modellen vandføringen y_{t+k} baseret på data til og med tid t , hvilket simulerer et realistisk forudsigelsesscenarie. For at estimere den fremtidige nedbør, som ikke er kendt i praksis, benyttes et lavpasfiltreret signal, skubbet k dage frem.

Ved hver tidsiteration benyttes den aktuelle inputvektor:

$$x_t = \left[1, y_{t-1}, \tilde{p}_{t+k}, X_1^{(t+k)}, X_2^{(t+k)} \right]$$

hvor $X_i^{(t+k)}$ repræsenterer fremtidige værdier af de valgte features, forskudt k dage. Modellens output er en lineær kombination af inputvektoren og parametervektoren θ , der opdateres løbende som beskrevet tidligere i Ligning (7)

6.4 Model 2: LSTM-model

Ud over ARX-modellen er der udviklet en mere kompleks LSTM model. Modellen er implementeret i TensorFlow og kombinerer historiske sekvenser med samtidige vejrprognose-variable, hvilket tillader den at lære ikke-lineære og tidsafhængige mønstre [18].

6.4.1 Modelopstilling & implementering

LSTM-modellen er baseret på to inputgrene:

- En historiksekvens med en længde på 10 dage (window size = 10).
- Et sæt features for forecast-dagen $t + k$.

De historiske features indeholder altid baseline-variable²:

- y
- Nedbørsmængde

²`Year.sin` & `Year.cos` repræsenterer årstidens cykliske mønstre og er konstrueret ud fra dag-nummeret i året via en transformation til enhedscirkel.

- `Year_sin`
- `Year_cos`

Forecast-feature sættet indeholder de samme variable, dog med undtagelse af y , da dette er modelens targetvariabel. Yderligere inputvariable blev tilføjet iterativt via en forward selection-proces, hvor kandidater blev evalueret på baggrund af RMSE over testperioden, og tilføjet til både den historiske sekvens og forecast-sekvensen.

De features, der blev udvalgt som bedst egnede, var:

- **Minimumstemperatur:** Laveste temperatur målt for hvert døgn, målt i $^{\circ}\text{C}$
- **Vindhastighed:** Gennemsnitshastigheden pr. dag, målt i m/s
- **Nedbørsvarighed:** Antal minutter det har regnet i løbet af det seneste døgn målt i minutter.


Det vil altså sige at det historiske input for modellen har en dimension på 10×7 , som består af 10 tidligere dages værdier af de 7 variable nævnt. Derudover har forecast-vektoren en længde på 6, da den ikke inkluderer target variabelen. Grunden til at input er delt op i en historisk sekvens og en forecast-vektor, er at et LSTM-netværk kræver sekventielle data som input og ikke bare data fra en enkelt dag.

Selve modellen består derfor af to grene, som hver bearbejder forskellige typer input og derefter kombineres i en fælles beslutningsstruktur.

- **Historisk gren:** Denne gren modtager et vindue af historiske data bestående af sekventielle inputfunktioner som fx observeret vandføring, nedbør og årstidssignaler. Inputtet går gennem et LSTM-lag med 64 units, som bearbejder tidlige mønstre i sekvensen. Outputtet fra LSTM'en opsummerer hele sekvensen i en vektor på 64 værdier, som derefter sendes gennem et fuldt forbundet lag (Dense-lag) med 64 units og ReLU-aktivering.
- **Forecast-gren:** De forecast-relaterede features samles i én vektor og bearbejdes gennem to Dense-lag, hver med 32 neuroner og ReLU-aktivering. Denne del af modellen håndterer de input som ikke har en sekventiel struktur.
- **Sammenkobling:** Outputtet fra de to grene (hhv. 64 og 32 dimensioner) kombineres ved hjælp af et Concatenate-lag, som samler dem i én samlet vektor på 96 dimensioner. Denne vektor sendes videre gennem et Dense-lag med 64 units og til sidst et outputlag med én neuron, som leverer den endelige forudsigelse. En visualisering af LSTM-modellen kan ses i Figur 15

Modellen er implementeret som en offline forecasting-struktur. Data samles først for hele historikken, hvorefter modellen trænes, evalueres på valideringssættet og testes på et testsættet. Metoden adskiller sig fra ARX-modellen, som opdaterer online. For hver forecast-horisont $k \in \{1, 2, 3, 4, 5\}$ trænes en separat model, hvilket giver mulighed for at lære forskellige mønstre afhængigt af hvor langt frem i tiden der forudsiges.

Modellen optimeres via MSE-loss og Adam-optimering. Derudover anvendes early stopping, hvor træningen automatisk stopper, hvis valideringstabstabet ikke forbedres over et bestemt antal epochs (i dette projekt 5) for at undgå overfitting.



Figur 15: Skematisk oversigt over den anvendte LSTM-arkitektur. Hver blok (fx LSTM (64)) repræsenterer ét lag med angivet antal interne enheder. Linjerne mellem de forskellige celler indikerer fuld forbindelse mellem lag, ikke individuelle én-til-én forbindelser.

6.5 Evalueringsmetrikker

For at evaluere præstationen af de udviklede prognosemodeller er der anvendt flere kvantitative metrikker. Den primære målsætning med projektet er ikke blot at minimere den gennemsnitlige fejl over hele perioden, men også at sikre en pålidelig forudsigelse af ekstreme vandføringer, som kan føre til oversvømmelser. På denne baggrund anvendes følgende evalueringsmål:

- **Root Mean Squared Error (RMSE)**: RMSE måler den gennemsnitlige størrelse af fejlene mellem de observerede og modellerede værdier. En lav RMSE indikerer, at modellen generelt forudsiger med høj præcision. RMSE er særligt følsom over for store fejl, hvilket gør den nyttig til at vurdere modellens præcision, især når store afvigelser er kritiske [41]. Den beregnes som:

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2} \quad (22)$$

hvor y_t er den observerede værdi, $\hat{y}_t$ er modelens forudsigelse, og n er antal observationer.

- **Extreme RMSE (Top 10%)**: For at vurdere modellens evne til helt specifikt at håndtere ekstreme hændelser er RMSE desuden beregnet separat for de 10% højeste observerede vandføringer i testdata. Dette giver et mål for den gennemsnitlige fejl i netop de kritiske perioder.
- **Critical Success Index (CSI)**: CSI kvantificerer modellens evne til korrekt at identificere og klassificere ekstreme hændelser. CSI defineres som:

$$\text{CSI} = \frac{TP}{TP + FP + FN} \quad (23)$$

hvor TP er antallet af korrekt forudsagte ekstreme hændelser (True Positives), FP er antallet af falske alarmer (False Positives), og FN er antallet af missede ekstreme hændelser (False Negatives).

Negatives). En høj CSI-værdi (nær 1) indikerer, at modellen effektivt fanger de hændelser, der er mest kritiske i forhold til oversvømmelsesrisiko [41].

Ved at kombinere disse metrikker kan der opnås en nuanceret vurdering af modellens præstation både under normale og ekstreme forhold.

6.5.1 Ekstreme hændelser

Ekstreme hændelser defineres i projektet som vandføringer, der overstiger 90%-percentilen af de historiske daglige observationer, svarende til de 10% højeste vandføringsværdier. Denne tærskel er valgt for også at fokusere analysen på de perioder, hvor risikoen for oversvømmelser er størst [7, 8].


I evalueringen klassificeres modellens forudsigelser mod denne tærskel:

- Hvis både den observerede og den forudsagte vandføring overstiger tærsklen, klassificeres hændelsen som en True Positive.
- Hvis den forudsagte vandføring overstiger tærsklen, men den observerede ikke gør, registreres en False Positive.
- Hvis den observerede vandføring overstiger tærsklen, men modellen ikke forudsiger det, registreres en False Negative.

Samlet set sikrer denne tilgang, at evalueringen ikke alene fokuserer på modellens generelle nøjagtighed, men også på dens evne til at identificere og håndtere de mest kritiske situationer.

7 Resultater

7.1 Hele testsættet




Figur 16: RMSE som funktion af horisonten (k) for LSTM, RLS og Persistence modellerne.

Figur 16 viser udviklingen i RMSE for de tre modeller — persistence, RLS og LSTM — som funktion af forecast horisonten $k \in \{1, 2, 3, 4, 5\}$. På tværs af alle horisonter præsterer LSTM-modellen bedst med lavest RMSE, efterfulgt af RLS og derefter persistence.

For horisont ($k = 1$) opnår LSTM-modellen en RMSE på cirka 330, hvilket er lavere end både RLS (ca. 380) og persistence (ca. 470). Forskellen mellem modellerne øges med stigende horisont. Ved $k = 5$ overstiger RMSE for RLS 1250, mens LSTM stadig holder sig under 720. RLS ligger tæt på LSTM ved de første to horisonter, men nærmer sig persistence ved længere horisonter.

LSTM-modellen viser desuden en mere flad stigning i fejl, hvilket indikerer, at den håndterer længere tidshorisonter bedre end de øvrige metoder. Samlet viser resultaterne, at LSTM konsekvent har lavere fejl og er mere robust over for øget forecast horisont, når man måler på hele testsættet.




Figur 17: Udsnit af observeret og modelleret vandføring (RLS vs. LSTM, $k=1$) – 15. juli til 15. september 2023

Figur 17 viser et tilfældigt udsnit af det observerede testdata og forudsigelser fra henholdsvis RLS- og LSTM-modellen for perioden 15. juli til 15. september 2023 med én dags horisont ($k=1$). Overordnet set, viser det at begge modeller formår at følge de større tendenser og dynamikker i data, både stigninger og fald, bliver meget forudsagt med nogenlunde præcision.

LSTM-modellen ser ud til konsekvent at undervurdere de tre peaks der forekommer, hvor RLS-modellen undervurdere de to første og lader til at overvurdere den sidste en smule. Det er dog svært ud fra dette udsnit at kommentere på hvilken model som klarer sig bedst, da begge modeller lader til at følge de observerede data nogenlunde, dog med en tendens til at undervurdere peaks.

For forudsigelser længere ud i fremtiden, bliver modellerne mere og mere ustabile, som også kan tolkes fra de stigende RMSE-værdier set i Figur 16. Samme udsnit af testdata med forudsigelser for $k = 2 - 5$ kan ses i bilag (30, 31, 32, 33)

7.2 Ekstreme hændelser




Figur 18: RMSE som funktion af horisonten (k) for LSTM, RLS og Persistence modellerne, kun evalueret på de top 10% ekstreme værdier i testsættet.

Figur 18 viser RMSE på tværs af horisonter for de 10% højeste værdier i testperioden. I modsætning til de samlede resultater klarer både LSTM og RLS modellerne sig her markant værre, særligt for længere horisonter.

Ved én dags horisont ($k = 1$) har LSTM og RLS en tæt RMSE omkring 700, dog viser LSTM en smule lavere RMSE. Allerede ved $k = 2$ er både persistence og RLS modellerne bedre end LSTM-modellen, hvor RLS ser ud til at være markant bedre end de to andre modeller. Ved $k = 5$ er LSTM bedst igen med lavest RMSE (ca. 1500), mens RLS klarer sig dårligst.

Dette indikerer, at LSTM har svært ved at håndtere de ekstreme udsving i vandføring, især ved horisonter på 2 og 3. RLS ligger lavest af alle tre modeller på netop dette horisontinterval.


Resultaterne peger på en stor usikkerhed i LSTM modellen afhængigt af horisontvalg. Her viser RLS en større robusthed end LSTM når det gælder ekstreme værdier, hvor det tyder på at LSTM's kompleksitet kan føre til større afvigelser i stedet for en større præcision.



Figur 19: Udsnit af observeret og modelleret vandføring med ekstreme hændelser (RLS vs. LSTM, $k=1$) – Dec 2022 til Jan 2023.

Figur 19 viser et udsnit af testdata i perioden december 2022 til januar 2023, hvor flere ekstreme vandføringshændelser optræder. Figuren sammenligner observerede værdier med forudsigelser fra RLS- og LSTM-modellen for én dags horisont ($k = 1$). De røde prikker indikerer at datapunkterne er en del af de 10% højeste observerede værdier i testdata og anses som værende ekstreme hændelser.

Ved første kig, ligner det at modellerne generelt følger den observerede data, selv i de ekstreme perioder, men ser man nærmere på f.eks. 2022-12-20 (altså dagen før den første ekstreme hændelse), ser man at både RLS og LSTM modellen forudsiger en vandføring på mellem 1000-1500 l/s, hvor den observerede vandføring ligger på 4000 l/s. Denne hændelse anses ikke for at være ekstrem, selvom den indeholder en stor stigning på over 3000 l/s fra dagen før. Dagen efter (2022-12-21), kommer begge modeller efter det og følger sådan set den resterende del af tidsserien meget pænt. Den 2022-12-20, er dog et godt eksempel på en svaghed i modellerne. Samme udsnit af testdata med forudsigelser for $k = 2 - 5$ kan ses i bilag (34, 35, 36, 37)



Figur 20: Critical Success Index (CSI) for ekstreme hændelser som funktion af horisont (k)

Figur 20 viser CSI som funktion af forecast horisont k . Ved horisont $k = 1$ præsterer både LSTM og RLS stærkt med CSI-værdier over 0.8, hvilket indikerer høj præcision i forudsigelsen af ekstreme tilfælde. Persistence ligger her lavere med en værdi på ca. 0.72. RLS modellen klarer sig en smule bedre end LSTM for $k = 1$, hvor alle modeller så falder drastigt ned og ligger tæt samlet for de resterende k . For alle modeller gælder at CSI falder markant med stigende horisont. For $k = 5$ er CSI under 0.4 for alle tre modeller.

7.3 Residualanalyse


	Hele testperioden	Top 10 % ekstreme
RLS		
Middelværdi	1.8	-89.4
Median	5.9	-74.5
LSTM		
Middelværdi	-37.8	-250.3
Median	6.7	-261.8

Tabel 2: Tabel over middelværdi og median af residualerne for RLS og LSTM på hele testperioden og for de ekstreme observationer (top 10 %) ($k=1$)


Som vist i Tabel 2 har RLS-modellen, hvis man kigger på hele testperioden, en forholdsvis afstemt model, der i gennemsnit kun har en residual på 1.8. LSTM-modellen har en værdi på -37.8 . LSTM modellen har derfor en tendens til at undervurdere de faktiske observationer, hvorimod RLS-modellen har en meget lille tendens til at overvurdere, hvilket ses ved at de gennemsnitlige residualer er henholdsvis negativ og positiv. Kigger man på deres medianer, har de næsten ens værdier på 5.9 og 6.7, hvilket fortæller at begge modeller oftest overvurdere vandføringen. Da LSTM-modellen har en negativ middelværdi samtidigt med en lille positiv median, må den altså have nogle store negative residualer som trækker middelværdien i den retning.

Forskellen bliver markant større ved de ekstreme observationer. Her undervurderer RLS i gennemsnit med -89.4 , mens LSTM har en væsentligt større negativ middelværdi på -250.3 . Begge modeller har altså svært ved at forecaste de ekstreme værdier som bliver observeret og har en stor tendens til at undervurdere en ekstrem begivenhed. Derudover ses det også på medianerne, at begge modeller oftest forudsiger lavere vandføringer end de faktiske. Her har RLS en median på -74.5 og LSTM en median på -261.8 , hvilket tyder på at LSTM-modellen har en stor negativ bias, selvom den ellers klarer sig bedre 'RMSE-mæssigt' i de foregående figurer.

For at skabe et bedre overblik over residualerne ses i figur 21 to QQ-plot af residualerne for RLS- (øverst) og LSTM-modellen (nederst) for en dags horisont.



(a) QQ-plot af RLS residualer ($k=1$)



(b) QQ-plot af LSTM residualer ($k=1$)

Figur 21: Sammenligning af QQ-plots for RLS (øverst) og LSTM (nederst) residualer ved $k = 1$.

For begge modeller ses en relativt symmetrisk afvigelse omkring nul, men med tydelige afvigelser i begge ender af fordelingerne. De ekstreme residualer – både positive og negative – ligger et godt stykke fra linjerne, hvilket viser, at fejlene ikke er normalt fordelt og at begge modeller har

problemer med at håndtere outliers. Dog følger størstedelen af punkterne i midterområdet den teoretiske fordeling rimeligt godt.

For LSTM-modellen ses dog en mere markant afvigelse i den venstre hale. Her er de mest ekstreme negative residualer endnu længere væk fra normalfordelingen end i RLS-modellen, hvilket stemmer overens med de resultater fra tabel 2 om LSTM's tendens til at undervurdere ekstreme værdier. Den højre hale følger til gengæld den teoretiske linje en smule bedre end RLS, hvilket kan indikere at LSTM-modellen ikke overvurdere lige så meget som RLS-modellen.

Samlet set viser QQ-plotsne at ingen af modellerne har normalfordelte residualer og at LSTM i højere grad producerer store negative fejl i forhold til RLS-modellen.

8 Diskussion

8.1 Hvilken model er bedst?

At vurdere hvilken model der er “bedst” afhænger af, hvordan man definerer succes. I denne kontekst kan det både handle om lav RMSE på hele testsættet, evnen til at håndtere ekstreme hændelser, bias i residualer, stabilitet over tid eller praktisk anvendelighed.

Hvis kriteriet udelukkende er forudsigelsesnøjagtighed målt ved RMSE på hele testsættet, er LSTM-modellen tydelig vinder. Den præsterer konsekvent med lavest RMSE på tværs af forecasthorisonterne og udviser også den mest stabile fejlvækst. Hvor RLS og især persistence fejler markant ved længere horisonter, formår LSTM at opretholde relativ lav fejl selv ved $k = 5$. Det gør LSTM til den mest robuste model, når målet er præcise prognoser over længere tid målt på hele testsættet.

Men billedet ændrer sig når man isolerer de ekstreme hændelser. Her ses en tydelig forringelse i LSTM's performance. Særligt ved horisonterne $k = 2$ og $k = 3$ er RMSE markant højere for LSTM end både RLS og persistence. Det tyder på, at LSTM har sværere ved at fange de pludselige opadgående udsving i flow, som ofte kendetegner ekstreme hændelser. Ved $k = 5$ præsterer LSTM bedre igen, men den store variation mellem horisonterne peger på en relativt stor ustabilitet og følsomhed i modellen.

RLS-modellen, derimod, præsterer mere balanceret. Selvom den har højere gennemsnitlig RMSE end LSTM over hele testsættet, klarer den sig væsentligt bedre i de ekstreme tilfælde – både i form af lavere residual bias og lavere fejl ved mellem-lange horisonter. Dens gennemsnitlige residual på kun -89.4 (mod LSTM's -250.3) ved ekstreme hændelser tyder på, at den er bedre kalibreret og har mindre systematisk tendens til at undervurdere de høje flow. For mange praktiske anvendelser, hvor konsekvenserne af at undervurdere en ekstrem hændelse kan være alvorlige, kan dette veje tungere end en lidt højere gennemsnitlig RMSE.

Samlet set kan man ikke udpege én entydigt “bedste” model. LSTM klarer sig bedst på general performance og lange horisonter, mens RLS er stærkere ved ekstreme hændelser og viser mindre bias. I en operationel kontekst, hvor håndtering af ekstreme hændelser kommer til at være afgørende, fremstår RLS som den mest robuste og anvendelige løsning. LSTM har dog et tydeligt potentiale til at overgå RLS, hvis modellens stabilitet og pålidelighed ved ekstreme udsving kan forbedres.

8.1.1 Vurdering af evalueringsmetrikker

Valget af evalueringsmetrik har stor betydning for, hvordan modellerne vurderes – og dermed også, hvilken model der i sidste ende fremstår “bedst”. I projektet er der anvendt RMSE, CSI og residualanalyser, som hver har deres styrker og begrænsninger.

RMSE er en standardmetrik til at måle den gennemsnitlige forudsigelsesfejl og anvendes ofte som det primære mål for modelperformance i tidsserier. En væsentlig fordel ved RMSE er, at store fejl straffes hårdt, hvilket er relevant i situationer, hvor store afvigelser i forecasts helst skal undgås. Det gør metrikken særligt velegnet til at vurdere modellens overordnede nøjagtighed. Ulempen er dog, at RMSE er følsom overfor enkelte ekstreme outliers. Dette kan være en udfordring i datasæt med ujævne mønstre og sjældne, men kraftige peaks som ses dette vores projekt.

CSI fokuserer udelukkende på evnen til at fange ekstreme hændelser – altså hvor godt modellen klassificerer om en hændelse er ekstrem eller ej. Den tager ikke højde for hvor langt modellen er fra den faktiske værdi, blot om den korrekt har identificeret den som “ekstrem”. Det kan føre til situationer, hvor en model har høj CSI, men stadig rammer 2–300 l/s forkert i det faktiske niveau. I

praksis kan det betyde, at modellen formelt set “fanger” hændelsen, men alligevel giver et misvisende signal i forhold til hvor alvorlig situationen reelt er. Her bliver metrikken altså blind for forskellen mellem “næsten rigtig” og “for langt fra”.

Residualanalyserne giver derfor et vigtigt supplement. De viser både bias og fejls retning – altså om modellen systematisk over- eller undervurderer. Det er særligt vigtigt ved ekstreme hændelser, hvor der i praksis er stor forskel på at ramme lidt for højt eller konsekvent for lavt. I mange operationelle sammenhænge, såsom slusestyring, vil det ofte være mere acceptabelt, at modellen overvurderer en smule, end at den konsekvent undervurderer – da sidstnævnte øger risikoen for at reagere for sent. For eksempel ses det i resultaterne, at både LSTM og RLS undervurderer vandføringen ved ekstreme hændelser, men at LSTM’s fejl er en del større. Det fremgår ikke tydeligt af RMSE eller CSI alene, men står klart i residualtabellen.

Det samlede billede viser derfor også, at ingen enkelt metrik er tilstrækkelig. RMSE giver et godt helhedsbillede, CSI fanger det klassifikatoriske aspekt og residualer afslører den systematiske skævhed der kan finde sted. Den bedste vurdering af en models praktiske anvendelighed opnås derfor først, når alle tre anvendes sammen. Hvis kun én metrik vælges, risikerer man at overse afgørende svagheder i modellen.

8.1.2 Online vs offline forecasting

Projektets resultater understreger også forskellen mellem online og offline tilgang. RLS-modellen blev implementeret med en online RLS-algoritme med forgetting factor, som tillader løbende opdatering af parametre. Det har betydet, at modellen hurtigt har kunne tilpasse sig strukturelle ændringer i vandføring og vejrdato, hvilket oftest er en klar fordel i kontekster med sæsonskitte eller vejrekstremer. LSTM-modellen blev derimod trænet offline og holdt fast i de samme vægte gennem hele testperioden. Det, at LSTM-modellen ikke har kunne opdatere vægtene i løbet af testperioden kan være en væsentlig årsag til, at den får større bias i de ekstreme hændelser. Modellen tilpasser sig ikke løbende, og når sjældne eller nye hændelsestyper opstår, har den ingen mekanisme til at justere sin adfærd. RLS derimod justerer konstant sin vægtning af input og reagerer hurtigt på skift i data. Derfor bør modelvalg i praksis tage højde for den operationelle kontekst: Offline-modeller er stærke ved stabile mønstre og store datamængder, mens online-modeller er bedre, når forudsigelser skal opdateres løbende under foranderlige forhold, hvilket de uden tvivl skal i denne sammenhæng.

8.2 Eksterne variable

Blandt de eksterne variable der blev testet, viste det sig at især nedbørsvarigheden var en vigtig ekstern variabel, da den blev valgt af både RLS og LSTM modellen. Det kunne tyde på, at information om varighed af nedbør, sammen med mængden af nedbør spiller en stor rolle, da man derigennem får information om nedbørsintensiteten. Det stemmer overens med den hydrologiske forståelse af oplandsrespons, hvor en kortvarig, intens byge ofte resulterer i langt mere overfladeafstrømning end en langvarig periode med støvregn, da infiltrationsevnen hurtigere overskrides [43].

Derudover blev strålingsintensitet, minimumstemperatur og vindhastighed også valgt som forklarende variable. Af de fire forskellige variable, viser det sig at både en strålingsrelateret og en temperaturrelateret variabel er blevet valgt. Lige netop de to variable stemmer overens med teorien bag Makkink-formlen, hvor globalstråling og temperatur er de to primære faktorer for ET_p . Selvom ET_p ikke direkte blev valgt af forward selection, tyder det på, at den muligvis indirekte er blevet indlejret via korrelerede variable. Det ses nemlig også af korrelationsmatricen i bilag 29, at netop

temperaturrelaterede og strålingsrelaterede variable, er de variable som korrelerer mest med ET_p (ET_0 i figuren).

8.3 Loss-funktioner & stationaritet

I projektet blev der anvendt klassiske MSE- og RMSE-baserede loss-funktioner til både modeltræning og evaluering. Disse metrikker forstærker effekten af både høje og lave outliers, da fejlene kvadreres. Det betyder, at modellen optimeres mod en lav gennemsnitlig fejl. Det tager dog ikke højde for at det i dette projekt primært er de største værdier, der bør vægtes højest. Set i lyset af projektets målsætning, kunne det være relevant at have udforsket en vægtet loss-funktion, hvor fejl over en vis tærskel (f.eks. 90-percentilen af vandføring) vægtes højere. Dette ville tvinge modellerne til at fokusere mere på de ekstreme hændelser, hvilket dog også kan føre til større fejl i mere almindelige situationer og føre til højere risiko for overfitting.

En anden overvejelse i løbet af projektet var spørgsmålet om stationaritet og deseasoning. I dette tilfælde blev dataserierne modelleret i deres oprindelige form uden at fjerne sæsonvariationer. Det skyldes dels, at det ikke blev prioriteret i den indledende dataforberedelse, snarere end et bevidst fravalg, og dels at LSTM-modellen i forvejen er i stand til at lære sæsonmønstre direkte fra data. For den lineære RLS-model kunne deseasoning teoretisk have givet en mere stabil og ensartet fejlstruktur over tid, men da modellen blev anvendt i et online setup og evalueret på realtidsdata, blev de sæsonmæssige mønstre i praksis bevaret. En efterfølgende analyse af residualerne set i bilag 28 viser dog, at fejlene fordeler sig omkring nul uden nogen tydelige trends, skift eller sæsonbetingede mønstre.

8.4 Begrænsninger & udfordringer i modellerne

Selvom både LSTM- og RLS-modellen har demonstreret fine resultater, er der en række begrænsninger, som bør adresseres, før de kan anvendes i praksis. Nogle af dem er metodiske som f.eks. modelkompleksitet, databehov og risiko for overfitting, mens andre er knyttet til datasættets kvalitet og hydrologiens karakter, herunder ikke-lineariteter, mangel på hændelseslabels og inputusikkerhed.

8.4.1 Modelkompleksitet & risiko for overfitting

LSTM-modellen indeholder mange justérbare parametre og er derfor fleksibel, men også sårbar overfor overfitting – især ved begrænsede datamængder og manglende repræsentation af ekstreme hændelser. I projektet blev risikoen for overfitting søgt reduceret gennem feature selection, men modellen viste alligevel en tendens til at undervurdere højflodssituationer. Det tyder på, at LSTM har haft svært ved at generalisere til de ekstreme hændelser uden mange direkte tilsvarende eksempler i træningssættet. Neurale netværk er generelt stærke til interpolation, men har begrænset evne til at ekstrapolere til sjældne scenarier som f.eks. en ”100-års hændelse” [23].

RLS-modellen er mindre kompleks og derfor mindre tilbøjelig til overfitting. RLS-algoritmens løbende tilpasning fungerer delvist som en indbygget regularisering, men kræver selvfølgelig en passende forgetting factor – ellers kan gamle mønstre fortsætte med at påvirke output uhensigtsmæssigt.

Der er dog risiko for at den lineære modellering i RLS-modellen kan komme til kort, da hydrologiske systemer er præget af tærskeladfærd og ikke-lineære sammenhænge, f.eks. hvor jorden er tør og kan absorbere vand, indtil en vis mætning nås – hvorefter alt yderligere nedbør løber af som overfladevand. LSTM-modellen er teoretisk set i stand til at repræsentere sådanne komplekse afhængigheder, men kun hvis den har tilstrækkeligt data til at lære dem. Manglen på ekstreme

eksempler kan gøre, at LSTM-modellen ender med at lære en slags ”gennemsnitlig linearitet”, hvor de ekstreme variationer stadig undervurderes [23].

RLS-modellen er lineær af natur, hvilket både er en styrke og en svaghed. Den er som set i dette projekt mere stabil og prædikerbar, men kan have svært ved at modellere de skarpe knæk og pludselige ændringer i responsen. I vores resultater klarede RLS sig faktisk bedre end LSTM ved flere af de ekstreme hændelser – muligvis fordi den ikke prøvede at overtilpasse sig, men blot ekstrapolerede jævnt ud fra historiske mønstre.

8.4.2 Databegrænsninger

Daglig i stedet for timevis opløsning:

Projektet benytter daglige værdier, hvilket reducerer modellernes evne til at fange hurtige peaks og ændringer i afstrømningen – særligt under ekstreme hændelser. Mange relevante hydrologiske processer, herunder skybrud og hurtig overfladeafstrømning, udspiller sig på timebasis. Det betyder at det specifikke tidspunkt for nedbøren inden for et døgn kan få stor betydning. Regner det f.eks. tidligt på dagen, kan afstrømningen nå at reagere samme dag, mens en dag med sen nedbør kan medføre, at effekten først ses i vandføringen dagen efter. Denne forskydning i timing er usynlig for modellerne, som kun ser døgnmidler og døgnsummer, og kan dermed forvirre læringsprocessen og føre til upræcise forudsigelser. En finere tidsopløsning ville derfor uden tvivl kunne styrke modellernes evne til at genkende og reagere på den type hændelser, som typisk fører til skader og oversvømmelser.

Mangel på oversvømmelseslabels og uklar definition af hændelser:

En alvorlig begrænsning i projektet er også fraværet af labels for faktiske oversvømmelser. Analysen har taget udgangspunkt i, at ekstremt høj vandføring er en proxy for oversvømmelsesrisiko – men det er ikke nødvendigvis korrekt. Det kunne i lige så høj grad være en pludselig stigning i vandføringen som set i figur 19, der resulterede i en stor fejlforudsigelse for begge modeller. Det kunne derudover også være kombinationer af inputfaktorer, eller systemets aktuelle kapacitet (sø- og havniveau), der afgør om en hændelse bliver kritisk.

Uden faktiske hændelsesmarkeringer kan modellerne ikke trænes til at skelne mellem høj vandføring og reel risiko. Det gør dem mere egnede til at forudsige hydrologisk aktivitet end til at vurdere konsekvens. Havde der været adgang til en slags registreringer af sådanne hændelser, kunne modellerne trænes på de hændelser, der faktisk udgør en fare. Det ville også gøre det muligt at identificere hvilke mønstre – f.eks. hurtig stigning, vedvarende høj vandføring, eller specifikke kombinationer – der typisk går forud for en oversvømmelse.

Usikkerheder:

Modellerne i projektet er trænet og evalueret med allerede observerede vejrdato – altså perfekte informationer om fremtiden. Det betyder, at forudsigelserne for modellerne i projektet er teoretisk optimale. I virkelige situationer vil input komme fra vejrudsigter som selvfølgelig er forbundet med usikkerheder og fejl. Især ved ekstreme hændelser, hvor præcision i nedbørsmængde og timing er kritisk, kan selv små fejl i inputdata føre til store fejl i output. Det gør modellernes performance her en øvre grænse snarere end et realistisk forventningsniveau. At indarbejde usikkerhed i fremtidige modeller vil derfor også være afgørende.

8.5 Perspektivering

Resultaterne i projektet peger på et klart potentiale for at anvende datadrevne modeller som beslutningsstøtte ved slusestyring af Bygholm Sø. Særligt ved kortsigtede forecasts kan både LSTM

og RLS-modellen bidrage til bedre overblik over kommende vandføring og muliggøre mere proaktive tiltag i perioder med forhøjet risiko for oversvømmelser.

En pålidelig prognose fra en af modellerne vil give Horsens mulighed for at handle før det er for sent. For eksempel: hvis modellen forudsiger en markant stigning i vandføringen i løbet af det næste døgn, kan man vælge at lukke mere vand ud gennem slusen på forskud og dermed skabe mere kapacitet i søen. Det reducerer risikoen for, at Bygholm Å og Horsens by oversvømmes ukontrolleret eller at vandstanden i Bygholm sø når et kritisk niveau.

Men for at modellerne skal kunne bruges i automatiske eller operative sammenhæng, er der flere væsentlige mangler. For det første mangler der en helhedsforståelse af det hydrologiske system: søens aktuelle vandstand, havets vandstand og afløbskapacitet er ikke inkluderet i modellerne. Dette projekt har kun fokuseret på information om tilløbet, og altså ikke om hele systemets tilstand – og det er derfor stadig begrænset til som en helhed at kunne vurdere risikoen for en oversvømmelse.

8.5.1 Fremtidigt arbejde

For at føre projektet videre, ville et oplagt næste skridt være at udforske forskellige loss-funktioner for modellerne. Her kunne man tilføje weighted loss functions eller lignende. En anden oplagt forbedring ville være at man fokuserer helt specifikt på ekstreme hændelser. Her kunne det være optimalt f.eks. at have 'labels' for hvornår der har været oversvømmelser eller andre ekstreme hændelser. På den måde vil man kunne skræddersy modellen til at være forberedt på hvilke specifikke kombinationer af interne og eksterne variable som står til grund for de ekstreme hændelser.

Derudover kunne det være spændende at udforske mere avancerede modelarkitekturer af LSTM ved f.eks. at inkorporere attention-mekanismer, som kan hjælpe modellen med at identificere og vægte de vigtigste input-tidspunkter, såsom specifikke kraftige regnskyl højere i forudsigelsen [19] [1]. Det kan især være relevant ved ekstreme hændelser, hvor signalet ikke nødvendigvis ligger i de seneste input, men i mere fjern historik eller i særlige kombinationer af variable. Andre alternativer kunne være at udforske Gated Recurrent Units (GRU), som er en mere kompakt version af LSTM og kan være lettere at træne med mindre data [5].

En af de forbedringer som jeg tror ville gavne mest, ville være at arbejde med timebaseret data i stedet for daglig data. Dette ville gøre det muligt at fange hurtige ændringer i vandføring – f.eks. ved kraftige byger – og dermed forbedre modellernes evne til at forudsige korte, men intense hændelser. Timevis data vil også give bedre indsigt i responstiden mellem nedbør og afstrømning, hvilket er virkelig afgørende for tidlig varsling. Derudover vil timevis data også skabe et 24 gange så stort datasæt, hvilket uden tvivl ville gavne især LSTM-modellen, som nok også ville gavne af flere ekstreme observationer. Det er dog ikke noget, der umiddelbart kan lade sig gøre i dette projekt, da der ikke findes timevise data for perioden. Til gengæld kunne man begynde at indsamle og gemme data på timebasis fremadrettet, så det bliver muligt at arbejde med den slags modeller i fremtiden.

Fremtidige modeller bør også håndtere den usikkerhed, der er forbundet med inputdata – især vejrprognoser. I virkeligheden er fremtidige nedbør- og temperaturvariable selvfølgelig ikke kendt på forhånd, og har derfor en vis usikkerhed. Hvis man kun evaluerer modeller på tidligere observerede data, risikerer man at overvurdere deres faktiske anvendelighed.

9 Konklusion

Projektet har undersøgt, hvordan datadrevne modeller kan anvendes til kortsigtet forudsigelse af daglig vandføring i Horsens opland, med fokus på både gennemsnitlige og ekstreme vandføringshændelser. To modeller blev testet og sammenlignet: en lineær ARX-model opdateret via Recursive Least Squares (RLS) og et multigrens Long Short-Term Memory-netværk (LSTM).

På tværs af hele testsættet leverede LSTM-modellen den laveste forudsigelsesfejl og den største stabilitet. Ved 1-dags horisont ($k = 1$) lå RMSE på ca. 330 l/s for LSTM, sammenlignet med 380 l/s for RLS og 470 l/s for baseline. Selv ved længere horisonter ($k = 5$) fastholdt LSTM sin præcision. Modellens evne til at lære ikke-lineære og tidsafhængige mønstre gør den særlig velegnet til generel, daglig forecasting med længere sigt.

Under ekstreme hændelser ændrer billedet sig. Her viste RLS-modellen sig mere robust. Selvom den har højere samlet RMSE, præsterede RLS markant bedre ved outliers. Den gennemsnitlige residual for top 10% vandføring var -89.4 l/s mod -250.3 l/s for LSTM. RLS-modellens simple struktur og hurtige tilpasning via en forgetting factor gjorde modellen bedre egnet til at opfange pludselige udsving i vandføring.

Begge modeller havde gavn af at inkludere eksterne, meteorologiske variable. Det viste sig især, at nedbørsvarighed var en vigtig feature, da den blev valgt af både RLS og LSTM. Det peger på, at information om nedbørsintensitet spiller en central rolle i modellens evne til at forudsige vandføring. Det understøtter også den hydrologiske forståelse, hvor kortvarige, intense byger genererer langt større overfladeafstrømning end langvarig regn.

Derudover blev strålingsintensitet, minimumstemperatur og vindhastighed valgt som forklarende variable. Det er bemærkelsesværdigt, at både temperatur- og strålingsrelaterede variable blev udvalgt, da det kan være forbundet med evapotranspirations betydning for vandføring, da globalstråling og temperatur er nøgleparametre for udregningen af ET_p .

LSTM-modellen var struktureret som et multigrens netværk, hvor historiske værdier (vandføring, nedbør, årstidssignaler) blev behandlet i én gren, mens meteorologiske variable for forecastdagen (temperatur, vind, nedbørsvarighed) blev ført ind i en separat gren. Denne arkitektur tillod kompleks modellering, men resulterede også i udfordringer med at ekstrapolere til ekstreme værdier. RLS brugte derimod en mere klassisk tilgang, hvor laggede vandføringsdata og lavpasfiltreret nedbør kombineret med samtidige meteorologiske variable blev anvendt som lineære eksogene input.

På den baggrund kan det konkluderes, at:

- LSTM er mest velegnet til generel korttidsforudsigelse af daglig vandføring, især ved længere horisonter,
- RLS er mere pålidelig ved ekstreme hændelser og reagerer hurtigere på pludselige ændringer,
- Kombinerede input af hydrologiske og meteorologiske variable, især dem relateret til nedbørsintensitet og evapotranspiration, øger modelpræcisionen.

Valget af evalueringsmetrikker viste sig også afgørende. RMSE gav et godt gennemsnitligt indblik, men var ikke tilstrækkeligt alene. CSI gav indsigt i modellernes evne til at identificere ekstreme hændelser, dog ikke deres størrelse. Residualanalyser var derfor et nødvendigt supplement, og afslørede systematisk undervurdering i begge modeller, særligt i LSTM ved høje vandføringer.

Projektets resultater viser derfor, at datadrevne modeller har potentiale til at understøtte beslut-

ningstagnung i forbindelse med slusestyring og oversvømmelsesberedskab i oplande som Horsens. Modellerne kan dog i deres nuværende form ikke stå alene. For praktisk implementering kræves en udvidet håndtering af usikkerhed, realistiske vejrinput og bedre modellering af ekstreme hændelser.

Litteratur

- [1] Hossein Abbasimehr og Reza Paki. “Improving time series forecasting using LSTM and attention models”. I: *Journal of Ambient Intelligence and Humanized Computing* 13.1 (jan. 2022), s. 673–691. ISSN: 18685145. DOI: 10.1007/s12652-020-02761-x.
- [2] M. B. Abbott m.fl. “An introduction to the European Hydrological System - Systeme Hydrologique Europeen, ”SHE”, 1: History and philosophy of a physically-based, distributed modelling system”. I: *Journal of Hydrology* 87 (okt. 1986), s. 45–59. ISSN: 00221694. DOI: 10.1016/0022-1694(86)90114-9.
- [3] G. Box og G. M. Jenkins. *Time Series Analysis: Forecasting and Control*. Tekn. rapp. 1976.
- [4] Philipp Brun m.fl. “Global climate-related predictors at kilometer resolution for the past and future”. I: *Earth System Science Data* 14 (dec. 2022), s. 5573–5603. ISSN: 18663516. DOI: 10.5194/essd-14-5573-2022.
- [5] Sayed Dawdy. *Time Series Prediction with GRU*. 2024.
- [6] DMI. *DMI Open Data*. 2025.
- [7] Allan Frei, Kenneth E. Kunkel og Adao Matonse. “The seasonal nature of extreme hydrological events in the northeastern United States”. I: *Journal of Hydrometeorology* 16.5 (2015), s. 2065–2085. ISSN: 15257541. DOI: 10.1175/JHM-D-14-0237.1.
- [8] Solomon H. Gebrechorkos m.fl. “Global-scale evaluation of precipitation datasets for hydrological modelling”. I: *Hydrology and Earth System Sciences* 28.14 (jul. 2024), s. 3099–3118. ISSN: 16077938. DOI: 10.5194/hess-28-3099-2024.
- [9] Sebastian Gegenleithner m.fl. “Long short-term memory networks for enhancing real-time flood forecasts: a case study for an underperforming hydrologic model”. I: *Hydrology and Earth System Sciences* 29.7 (apr. 2025), s. 1939–1962. ISSN: 16077938. DOI: 10.5194/hess-29-1939-2025.
- [10] Baya Hadid, Eric Duviella og Stéphane Lecoeuche. “Data-driven modeling for river flood forecasting based on a piecewise linear ARX system identification”. I: *Journal of Process Control* 86 (feb. 2020), s. 44–56. ISSN: 09591524. DOI: 10.1016/j.jprocont.2019.12.007.
- [11] Nicolai Garder Hansen. *Forecasting-water-inflow*. 2025. URL: <https://github.com/nicolaigarder/Forecasting-water-inflow>.
- [12] Sepp Hochreiter og Jurgen Schmidhuber. “Long Short-Term Memory”. I: (1997).
- [13] Robert E. Horton. “The Rôle of infiltration in the hydrologic cycle”. I: *Eos, Transactions American Geophysical Union* 14.1 (1933), s. 446–460. ISSN: 23249250. DOI: 10.1029/TR014i001p00446.
- [14] IPCC. *Climate change 2014 : synthesis report : longer report*. [Intergovernmental Panel on Climate Change], 2015, s. 116. ISBN: 9789291691432.
- [15] Jaesung Jung og Robert P. Broadwater. *Current status and future advances for wind speed and power forecasting*. 2014. DOI: 10.1016/j.rser.2013.12.054.
- [16] T R Kjeldsen og D A Jones. *Recursive estimation of a hydrological regression model*. Tekn. rapp. 2007. URL: <http://nora.nerc.ac.uk/policies.html#access>.
- [17] Pavel Klushin. *Online vs Offline Machine Learning – What’s the Difference? — JFrog ML*. 2022.
- [18] Frederik Kratzert m.fl. “NeuralHydrology – Interpreting LSTMs in Hydrology”. I: (mar. 2019). DOI: 10.1007/978-3-030-28954-6{_}19. URL: <http://arxiv.org/abs/1903.07903>http://dx.doi.org/10.1007/978-3-030-28954-6_19.
- [19] Dr. Ernesto Lee. *Revolutionizing Time Series Prediction with LSTM with the Attention Mechanism*. 2024.

- [20] Zhangjun Liu m.fl. “Comparative Study of Three Updating Procedures for Real-Time Flood Forecasting”. I: *Water Resources Management* 30.7 (maj 2016), s. 2111–2126. ISSN: 15731650. DOI: 10.1007/s11269-016-1275-0.
- [21] Guilan Luo m.fl. “Prediction of Extreme Precipitation Events Based on LSTM-Self Attention Model”. I: *ACM International Conference Proceeding Series*. Association for Computing Machinery, jan. 2024, s. 91–97. ISBN: 9798400707971. DOI: 10.1145/3640824.3640838.
- [22] Henrik Madsen. *Time Series Analysis CHAPMAN & HALL/CRC Texts in Statistical Science Series Analysis of Failure and Survival Data The Analysis and Interpretation of Multivariate Data for Social Scientists*. Tekn. rapp.
- [23] Holger R Maier og Graeme C Dandy. *Neural networks for the prediction and forecasting of water resources variables: a review of modelling issues and applications*. Tekn. rapp. 2000, s. 101–124. URL: www.elsevier.com/locate/envsoft.
- [24] Harald E. Mikkelsen og Jørgen E. Olesen. *Sammenligning af metoder til bestemmelse af potentiel vandfordampning*. Tekn. rapp.
- [25] Neetu Mittal og Ashwani Kumar. “Analysis of supervised feature selection in bioinformatics”. I: *Blockchain Applications for Healthcare Informatics: beyond 5G*. Elsevier, jan. 2022, s. 431–446. ISBN: 9780323906159. DOI: 10.1016/B978-0-323-90615-9.00008-6.
- [26] Pernille Yde Nielsen. *Time Series Analysis Week 3-WLS and RLS with forgetting*. Tekn. rapp. 2025.
- [27] Chris Olah. *Understanding LSTM Networks*. 2015.
- [28] Niels Bering Ovesen m.fl. *Miljø-og Energiministeriet Danmarks Miljøundersøgelser Afstrømningsforhold i danske vandløb Faglig rapport fra DMU, nr. 340 2000*. Tekn. rapp. URL: <http://www.dmu.dk>.
- [29] David R. Maidment. *Handbook of Hydrology*. 1993.
- [30] Mikael Scharling. *DANISH METEOROLOGICAL INSTITUTE KLIMAGRID-DANMARK Sammenligning af potentiel fordampning beregnet ud fra Makkinks formel og den modificerede Penman formel*. Tekn. rapp.
- [31] Josh Starmer. *Long Short-Term Memory (LSTM), Clearly Explained*. 2022.
- [32] P C Tan m.fl. *Recursive Identification and Adaptive Prediction of Wastewater Flows**. Tekn. rapp. 5. 1991, s. 761–768.
- [33] L. Tarasova m.fl. “Exploring Controls on Rainfall-Runoff Events: 1. Time Series-Based Event Separation and Temporal Dynamics of Event Runoff Response in Germany”. I: *Water Resources Research* 54.10 (okt. 2018), s. 7711–7732. ISSN: 19447973. DOI: 10.1029/2018WR022587.
- [34] Vandportalen. *Vandportalen*. 2025.
- [35] Wikipedia. *Opland - Wikipedia, den frie encyklopædi*. 2023.
- [36] Wikipedia. *Ordinary least squares*. 2025.
- [37] Wikipedia. *Recurrent neural network*. 2025.
- [38] Wikipedia. *Recursive least squares filter*. 2025.
- [39] Wikipedia. *Stepwise regression*. 2025. DOI: 10.1214/aos/1176325766.
- [40] Wikipedia. *Stormen Bodil - Wikipedia, den frie encyklopædi*. 2024.
- [41] Daniel S. Wilks. “Forecast Verification”. I: *Statistical Methods in the Atmospheric Sciences*. Elsevier, 2019, s. 369–483. DOI: 10.1016/b978-0-12-815823-4.00009-2.
- [42] Niklas Winther-Have, Sara Karlskov og Anna Esbjørn. *NATURBASEREDE BYER*. Tekn. rapp. Apr. 2024.
- [43] Yiping Wu m.fl. “Rising rainfall intensity induces spatially divergent hydrological changes within a large river basin”. I: *Nature Communications* 15.1 (dec. 2024). ISSN: 20411723. DOI: 10.1038/s41467-023-44562-8.

- [44] Xiaobo Zhou, M. Helmers og Z. Qi. “Modeling of subsurface tile drainage using MIKE SHE”. I: *Applied Engineering in Agriculture* 29.6 (2013), s. 865–873. ISSN: 08838542. DOI: 10.13031/aea.29.9568.
- [45] Eric Zivot. *4 Time Series Concepts — Introduction to Computational Finance and Financial Econometrics with R*. 2022.

10 Bilag

Variabel	Daglig aggregationsfunktion	Manglende (antal)	Manglende (%)
temp_min_past1h	Min (min)	150	1.87
temp_max_past1h	Maks (max)	150	1.87
temp_mean_past1h	Middel (mean)	150	1.87
temp_grass_mean_past1h	Middel (mean)	138	1.72
temp_soil_min_past1h	Min (min)	138	1.72
temp_soil_max_past1h	Maks (max)	138	1.72
temp_soil_mean_past1h	Middel (mean)	138	1.72
humidity_past1h	Middel (mean)	160	1.99
pressure*	Middel (mean)	5931	73.88
wind_dir_past1h	Middel (mean)	143	1.78
wind_min_past1h*	Min (min)	6245	77.79
wind_gust_always_past1h	Maks (max)	758	9.44
wind_speed_past1h	Middel (mean)	143	1.78
precip_past1h	Sum (sum)	0	0.00
precip_dur_past1h	Sum (sum)	0	0.00
radia_glob_past1h	Sum (sum)	0	0.00
sun_last1h_glob	Sum (sum)	0	0.00
KarupBro	Middel (mean)	0	0.00


* Kolonner slettet pga. >50 % manglende data.

Tabel 3: Daglig aggregering og manglende værdier i de dagligt aggregerede vejrdato før behandling ($n = 8028$)


Databehandlingstrin

- Fjern kolonner med for mange manglende værdier.**
Andelen af NaN blev beregnet for hvert felt; kolonner med mere end 50 % manglende observationer blev droppet.
- Lineær interpolation af kortvarige huller.**
Gaps på op til 12 sammenhængende timer blev udfyldt med `interpolate(method='linear', limit=12, limit_direction='both')`.
- Sæsonaliseret mean-imputation for resterende manglende værdier.**
Hjælpekolonner (*hour*, *dayofyear*, *month*, *day*, *year*) blev tilføjet, og data blev grupperet på (*month*, *day*, *hour*); manglende celler blev erstattet af det lokale sæsongennemsnit.
- Oprydning og lagring.**
Hjælpekolonnerne blev fjernet igen, og det rensede sæt gemt som `dmi_weather_data_cleaned.csv`.
- Validering.**
Efter behandlingen blev antallet af resterende NaN udskrevet for at verificere, at alle manglende værdier var håndteret.


Figur 22: Databehandlingstrin




Figur 23: Notation af interaktioner i LSTM illustrationerne. Gengivet fra [27]




Figur 24: Zoom på de tre perioder med den højeste vandføring. Både vandføring og nedbør vises for at illustrere hændelsens udvikling.




Figur 25: Zoom på de tre perioder med den største nedbør. Både vandføring og nedbør vises for at illustrere hændelsens udvikling.




Figur 26: Histogram af vandføring




Figur 27: Histogram af nedbør med log(y)-akse




Figur 28: Tidsserie af residualer for RLS og LSTM på testdata (k=1)




Figur 29: Korrelationsmatrix af alle de hentede variable fra DMI




Figur 30: Udsnit af observeret og modelleret vandføring (RLS vs. LSTM, k=2) – 15. juli til 15. september 2023




Figur 31: Udsnit af observeret og modelleret vandføring (RLS vs. LSTM, k=3) – 15. juli til 15. september 2023




Figur 32: Udsnit af observeret og modelleret vandføring (RLS vs. LSTM, k=4) – 15. juli til 15. september 2023




Figur 33: Udsnit af observeret og modelleret vandføring (RLS vs. LSTM, k=5) – 15. juli til 15. september 2023




Figur 34: Udsnit af observeret og modelleret vandføring med ekstreme hændelser (RLS vs. LSTM, $k=2$) – Dec 2022 til Jan 2023.



Figur 35: Udsnit af observeret og modelleret vandføring med ekstreme hændelser (RLS vs. LSTM, $k=3$) – Dec 2022 til Jan 2023.



Figur 36: Udsnit af observeret og modelleret vandføring med ekstreme hændelser (RLS vs. LSTM, k=4) – Dec 2022 til Jan 2023.



Figur 37: Udsnit af observeret og modelleret vandføring med ekstreme hændelser (RLS vs. LSTM, k=5) – Dec 2022 til Jan 2023.

	Hele testperioden	Top 10% ekstreme
RLS		
Middelværdi	0,264 mm	−13,09 mm
LSTM		
Middelværdi	−5,54 mm	−36,65 mm

Tabel 4: Middelværdi af residualerne, omregnet fra l/s til vandstandsstigning (mm) over 59 ha. Medianværdierne står fortsat i l/s, da der ikke var bedt om at omregne dem.